

Politechnika Wrocławska
Wydział Informatyki i Telekomunikacji

Kierunek: **Informatyka techniczna (ITE)**
Specjalność: **Systemy Informatyki w Medycynie (IMT)**

PRACA DYPLOMOWA
MAGISTERSKA

**Wykorzystanie uczenia transferowego
we wspomaganiu diagnostyki
retinopatii cukrzycowej na podstawie
zdjęć siatkówki**

**Utilization of Transfer Learning in
supporting the diabetic retinopathy
diagnosis based on retinal fundus
images**

Wiktoria Jańska

Opiekun pracy
Dr inż. Paweł Zyblewski

Słowa kluczowe: uczenie maszynowe, klasyfikacja, uczenie głębokie, implementacja

WROCŁAW, 2025

Streszczenie

W ostatnich latach obserwuje się dynamiczny rozwój technologii, w tym sztucznej inteligencji, która znajduje coraz szersze zastosowanie w różnych sektorach, ze szczególnym uwzględnieniem medycyny. Wczesna diagnoza chorób stanowi jeden z kluczowych obszarów, w których AI może znacząco wpłynąć na poprawę efektywności i trafności rozpoznań. Niniejsza praca koncentruje się na zastosowaniu uczenia transferowego w diagnostyce retinopatii cukrzycowej - powikłania cukrzycy o rosnącym znaczeniu klinicznym, zwłaszcza w populacji osób w wieku produkcyjnym. Przeprowadzono analizę współczesnych modeli głębokiego uczenia pod kątem ich zdolności do transferu wiedzy oraz efektywności klasyfikacji stopnia zaawansowania retinopatii cukrzycowej. Dodatkowo oceniono zachowanie tych modeli przy ograniczonej liczbie próbek, co jest istotnym zagadnieniem w kontekście ograniczonej dostępności danych medycznych. Obszary kluczowe dla klasyfikacji stopnia zaawansowania retinopatii cukrzycowej zwizualizowano za pomocą metod wyjaśnialnej sztucznej inteligencji, co pozwoliło na interpretację kryteriów decyzyjnych modeli.

Efektem pracy jest szczegółowa ocena wybranych architektur sieci neuronowych pod kątem ich zastosowania w diagnostyce retinopatii cukrzycowej, uwzględniająca różne aspekty funkcjonowania modeli w tym specyficznym zadaniu.

Abstract

Recent years have seen the rapid development of technology, including artificial intelligence, which is finding increasing application in various sectors, with a particular focus on medicine. Early diagnosis of diseases is one of the key areas where AI can significantly improve the efficiency and accuracy of diagnoses. This paper focuses on the application of transfer learning in the diagnosis of diabetic retinopathy - a diabetes complication of increasing clinical importance, especially in the working-age population. An analysis of contemporary deep learning models was conducted in terms of their ability to transfer knowledge and their effectiveness in classifying the severity of diabetic retinopathy. In addition, the behavior of these models with a limited number of samples was evaluated, which is an important issue in the context of limited availability of medical data. Key areas for the classification of the severity of diabetic retinopathy were visualized using methods of explainable artificial intelligence, which allowed interpretation of the models' decision criteria.

The result of the work is a detailed evaluation of selected neural network architectures for their application in the diagnosis of diabetic retinopathy, taking into account various aspects of the models' performance in this specific task.

Spis treści

1. Wstęp	5
1.1. Wprowadzenie	5
1.2. Cel pracy	6
1.3. Układ dokumentu	7
2. Przegląd literatury	8
2.1. Uczenie maszynowe	8
2.2. Zadanie klasyfikacji	9
2.3. Wykorzystanie głębokich sieci w analizie obrazów medycznych	9
2.4. Modele głębokiego uczenia	13
2.4.1. RetFound MAE	13
2.4.2. MedViT	13
2.4.3. Swin Transformers	14
2.4.4. ResNet50	14
2.5. Przegląd istniejących metod diagnostyki retinopatii cukrzycowej	14
2.6. Metody ewaluacji	16
2.6.1. Walidacja krzyżowa	16
2.6.2. Metryki ewaluacji skuteczności klasyfikacji	16
2.6.3. Metryki ewaluacji zdolności do transferu wiedzy	19
2.6.4. Redukcja wymiarowości i wizualizacja danych	21
2.7. Metody wyjaśnialnej sztucznej inteligencji	22
2.7.1. SHAP	22
2.7.2. GRAD-CAM	23
3. Protokół eksperymentalny i plany eksperymentów	25
3.1. Pytania badawcze	25
3.2. Zbiór danych i przetwarzanie wstępne danych	25
3.3. Przebieg eksperymentów	27
3.4. Scenariusze eksperymentów	29
3.4.1. Eksperyment 1 - Porównanie modeli pod kątem ich zdolności do transferu wiedzy	29
3.4.2. Eksperyment 2 - Porównanie modeli pod kątem klasyfikacji	29
3.4.3. Eksperyment 3 - Porównanie modeli pod kątem klasyfikacji w przypadku ograniczonych danych	30
3.4.4. Eksperyment 4 - Wyjaśnialność	30
4. Eksperymenty i wyniki	31
4.1. Ewaluacja wyników pod kątem zdolności do transferu wiedzy	31
4.2. Ewaluacja wyników pod kątem skuteczności klasyfikacji wieloklasowej	36
4.3. Analiza zachowania modeli uczenia maszynowego w warunkach ograniczonej dostępności danych	39
4.4. Wyjaśnialność	42

5. Wyzwania i ograniczenia	45
5.1. Implementacja modeli oraz przetwarzanie obrazów	45
5.2. Interpretacja metryk badających zdolność do transferu wiedzy	45
5.3. Ograniczenia sprzętowe	46
6. Podsumowanie	47
6.1. Efekt końcowy pracy	47
6.2. Możliwe ścieżki rozwoju	48
Literatura	50

Rozdział 1

Wstęp

W poniższym rozdziale został opisany cel oraz zakres pracy, a także przedstawiono układ dokumentu.

1.1. Wprowadzenie

Retinopatia cukrzycowa (ang. *diabetic retinopathy*) [1] jest głównym powikłaniem dla osób chorujących na cukrzycę i niesie ze sobą poważne konsekwencje zdrowotne. Jest to schorzenie siatkówki, które rozwija się w wyniku uszkodzenia drobnych naczyń krwionośnych oka.

W początkowej fazie może przebiegać bezobjawowo, jednak w miarę postępu choroby prowadzi do pogorszenia ostrości widzenia, a w skrajnych przypadkach - do całkowitej utraty wzroku. Według danych Światowej Organizacji Zdrowia, retinopatia cukrzycowa jest jedną z głównych przyczyn ślepoty wśród osób w wieku produkcyjnym na świecie [2].

Skuteczna diagnostyka retinopatii cukrzycowej opiera się na regularnych badaniach obrazowych dna oka, takich jak fotografia siatkówki, nazywana retinografią. Niestety, dostęp do specjalistów okulistyki i czasochłonność ręcznej analizy zdjęć ograniczają możliwości wczesnego wykrywania choroby na szeroką skalę. W tym kontekście coraz większe znaczenie zyskują metody automatycznej analizy obrazów, oparte na głębokim uczeniu, które wykazują wysoką skuteczność w zadaniach klasyfikacji obrazów medycznych. Wykorzystanie sztucznej inteligencji w diagnostyce chorób oczu [3] stwarza szansę na zwiększenie dostępności i efektywności badań przesiewowych. Pierwsze działające systemy pojawiły się już około 2016 roku i szybko udowodniły, że potrafią skutecznie wykrywać choroby siatkówki na podstawie zdjęć dna oka. Na rynku istnieje kilka sprawdzonych narzędzi, które oficjalnie są wykorzystywane w klinikach. Przykładowo, system IDx-DR, który jest jednym z pionierów, został zaakceptowany przez amerykańską Agencję Żywności i Leków (FDA) i działa w praktyce [4, 5], pomagając w automatycznej diagnozie. Inny system o nazwie EyeArt również ma podobne zatwierdzenia i jest używany w praktyce klinicznej. W Europie natomiast zyskał popularność system SELENA+, który poza retinopatią wykrywa także inne poważne schorzenia oczu i już niedługo ma być częścią narodowego programu badań przesiewowych w Singapurze [6].

Motywacją podjęcia tematyki niniejszej pracy jest nie tylko rosnące zapotrzebowanie na niezawodne, precyzyjne oraz interpretowalne narzędzia wspierające proces diagnostyczny, lecz również chęć przeprowadzenia szczegółowej analizy nowoczesnych modeli głębokiego uczenia w kontekście ich zastosowania w medycynie. W ostatnich latach sektor ochrony zdrowia wykazuje coraz większą otwartość na integrację rozwiązań opartych na sztucznej inteligencji, które mają potencjał znacząco poprawić efektywność i jakość świadczeń medycznych. Niemniej

jednak, kluczowymi wyzwaniami pozostają zagwarantowanie wysokiej skuteczności modeli, ich transparentność oraz zdolność adaptacji do zróżnicowanych i często ograniczonych pod względem rozmiaru i jakości danych medycznych. Szczególnie istotne jest zatem systematyczne zbadanie, które architektury sieci neuronowych charakteryzują się najwyższą efektywnością w rozwiązywaniu problemów diagnostycznych związanych z obrazowaniem medycznym, takich jak wykrywanie retinopatii cukrzycowej, a także w jakim stopniu potrafią one wykorzystać wcześniej zdobytą wiedzę oraz skutecznie przenieść ją na wąsko wyspecjalizowane, kliniczne zadania klasyfikacyjne.

Uczenie transferowe [7, 8] stanowi obecnie jedno z fundamentalnych podejść w obszarze przetwarzania obrazów medycznych, zwłaszcza w sytuacjach, gdy dostępne zbiory danych są niewielkie lub fragmentaryczne. Dzięki możliwości ponownego wykorzystania reprezentacji wyuczonych na rozległych, ogólnych bazach danych, uczenie transferowe umożliwia znaczne skrócenie czasu potrzebnego na trening modeli oraz istotną poprawę ich dokładności klasyfikacyjnej w zadaniach specjalistycznych. Takie podejście pozwala na osiągnięcie wysokiej jakości predykcji nawet przy ograniczonej liczbie przykładów treningowych specyficznych dla danego schorzenia, co jest nieocenione w kontekście medycyny, gdzie pozyskiwanie i anotacja danych są kosztowne i czasochłonne. Ponadto, zastosowanie zaawansowanych architektur głębokiego uczenia, w tym sieci konwolucyjnych oraz transformerów, sprzyja tworzeniu modeli bardziej odpornych na zakłócenia oraz lepiej generalizujących na nowe, nieznane przypadki kliniczne. W kontekście implementacji w systemach diagnostycznych, transfer learning staje się zatem podstawą efektywnego i skalowalnego procesu budowy narzędzi wspierających decyzje lekarskie, umożliwiając jednocześnie optymalizację wykorzystania ograniczonych zasobów danych.

1.2. Cel pracy

Celem niniejszej pracy jest analiza zdolności transferu wiedzy w wybranych, nowoczesnych modelach głębokiego uczenia, mająca na celu identyfikację architektur najlepiej przystosowanych do realizacji zadań diagnostycznych w dziedzinie medycyny. Wykorzystując jako punkt odniesienia problem detekcji retinopatii cukrzycowej na podstawie obrazów dna oka, praca podejmuje się analizy efektywności adaptacji modeli wytrenowanych na dużych, ogólnych zbiorach danych do wąsko zdefiniowanego i specjalistycznego zadania klasyfikacyjnego. Szczególna uwaga zostanie poświęcona ocenie, które z wybranych architektur wykazują największą zdolność do transferu nabytej wcześniej wiedzy oraz jej skutecznego zastosowania w kontekście rozpoznawania zmian patologicznych w siatkówce, co jest zadaniem o dużym znaczeniu klinicznym.

W dalszej części pracy wyselekcjonowane architektury sieci neuronowych zostaną poddane wnikliwej ewaluacji pod kątem ich skuteczności klasyfikacyjnej, przeprowadzanej na ogólnodostępnym zbiorze danych medycznych dedykowanym problematyce retinopatii. Szczególny nacisk zostanie położony na ocenę działania modeli w warunkach ograniczonej dostępności danych uczących, co odzwierciedla realne wyzwania praktyczne związane z pozyskiwaniem i anotacją danych medycznych. Analiza ta pozwoli na wytypowanie rozwiązań o najwyższym potencjale adaptacyjnym, gwarantujących jednocześnie stabilność i wiarygodność klasyfikacji w trudnych warunkach eksperymentalnych.

Ponadto, ważnym elementem badania będzie zastosowanie metod z zakresu wyjaśnialnej sztucznej inteligencji (XAI), które umożliwią szczegółową interpretację mechanizmów decyzyjnych poszczególnych modeli. Przez wskazanie i wizualizację obszarów obrazu dna

oka, które miały największy wpływ na końcową decyzję diagnostyczną modelu, analiza ta dostarczy informacji nie tylko o skuteczności, lecz także o transparentności działania sieci neuronowych. Takie podejście jest kluczowe z punktu widzenia potencjalnego wdrożenia systemów wspomagających diagnostykę w środowisku klinicznym, gdzie zaufanie i zrozumienie sposobu działania algorytmów mają fundamentalne znaczenie dla ich akceptacji przez personel medyczny oraz pacjentów.

1.3. Układ dokumentu

Niniejsza praca została podzielona na sześć głównych rozdziałów. W rozdziale pierwszym przedstawiono wprowadzenie do tematu, cel pracy oraz motywację stojącą za wyborem zagadnienia. Rozdział drugi stanowi przegląd literatury i zawiera omówienie podstawowych pojęć związanych z klasyfikacją obrazów, wykorzystaniem głębokiego uczenia w medycynie, przegląd istniejących rozwiązań problemu detekcji retinopatii cukrzycowej, a także opis metod z zakresu wyjaśnialnej sztucznej inteligencji. Rozdział trzeci opisuje protokół eksperymentalny - od zbioru danych, przez zastosowane modele, aż po planowane eksperymenty. W rozdziale czwartym zaprezentowano uzyskane wyniki ewaluacji modeli pod kątem zdolności do transferu wiedzy i skuteczności klasyfikacji, a także wyjaśnialność decyzji podejmowanych przez modele. Piąty rozdział porusza najważniejsze wyzwania i ograniczenia napotkane w trakcie realizacji pracy. Ostatni, szósty rozdział zawiera podsumowanie pracy oraz propozycje dalszych kierunków rozwoju.

Rozdział 2

Przegląd literatury

Rozdział ten przedstawia przegląd literatury z zakresu kluczowych zagadnień związanych z uczeniem maszynowym, klasyfikacją obrazów oraz zastosowaniem metod głębokiego uczenia w medycynie. Uwzględniono również istniejące podejścia do wykrywania retinopatii cukrzycowej, a także opisano wybrane techniki z obszaru wyjaśnialnej sztucznej inteligencji.

2.1. Uczenie maszynowe

Uczenie maszynowe [9, 10] (ang. *machine learning*) jest jedną z kluczowych dziedzin sztucznej inteligencji, koncentrującą się na projektowaniu oraz implementacji algorytmów umożliwiających tworzenie modeli statystycznych i probabilistycznych, które uczą się zależności i struktur na podstawie zbiorów danych wejściowych. Głównym celem tych metod jest automatyzacja procesu analizy danych w taki sposób, aby model mógł generalizować i podejmować decyzje dla wcześniej niewidzianych przykładów. Uczenie maszynowe można podzielić na trzy zasadnicze paradygmaty:

Uczenie nadzorowane (ang. *supervised learning*) opiera się na zbiorze treningowym składającym się z par: cech wejściowych oraz odpowiadających im etykiet klas (w zadaniach klasyfikacji) lub wartości liczbowych (w zadaniach regresji). Celem jest aproksymacja nieznanej funkcji odwzorowującej przestrzeń cech na przestrzeń wyników, co pozwala na przypisanie nowych danych do określonych klas lub oszacowanie wartości ciągłych. Proces uczenia polega na optymalizacji funkcji celu odpowiedniej dla danego algorytmu, co najczęściej oznacza minimalizację błędu predykcji, ale może również obejmować inne miary, takie jak nagroda czy rozbieżność rozkładów.

Uczenie nienadzorowane (ang. *unsupervised learning*) operuje na zbiorach danych pozbawionych etykiet. Celem tego podejścia jest identyfikacja ukrytych struktur, zależności lub rozkładów statystycznych w danych. Typowe zadania obejmują klasteryzację (grupowanie obserwacji o podobnych cechach), redukcję wymiarowości czy eksplorację anomalii.

Uczenie półnadzorowane (ang. *semi-supervised learning*) to podejście, które wykorzystuje zarówno dane etykietowane, jak i nieetykietowane w celu trenowania modelu. Jest szczególnie przydatne w sytuacjach, gdy pozyskiwanie adnotacji jest kosztowne lub czasochłonne, na przykład w analizie obrazów medycznych, gdzie potrzebna jest wiedza specjalistyczna.

W kontekście przetwarzania obrazów medycznych, które często charakteryzują się ograniczoną dostępnością danych, ich dużym zróżnicowaniem oraz wymogiem wysokiej precyzji diagnostycznej, szczególne znaczenie mają metody uczenia nadzorowanego i półnadzorowanego. Dzięki etykietowanym zbiorom, zawierającym na przykład adnotacje specjalistów, możliwe jest trenowanie modeli do zadań klasyfikacji patologii, lokalizacji zmian chorobowych lub

segmentacji struktur anatomicznych. W sytuacjach, gdy pełne etykietowanie danych jest kosztowne lub trudne, stosuje się uczenie półnadzorowane, łączące niewielką liczbę próbek etykietowanych z dużą liczbą danych nieetykietowanych, co pozwala poprawić zdolność modelu do generalizacji i zwiększyć jego skuteczność diagnostyczną.

2.2. Zadanie klasyfikacji

Klasyfikacja [9] jest jednym z fundamentalnych problemów uczenia nadzorowanego, polegającym na przypisaniu obserwacji $\mathbf{x} \in R^d$ do jednej z K dyskretnych klas $y \in \{1, 2, \dots, K\}$. Formalnie, zadaniem klasyfikatora jest wyuczenie funkcji $f : R^d \rightarrow \{1, \dots, K\}$, która dla nieznanego przykładu $\mathbf{x}$ przewiduje etykietę y z możliwie najmniejszym błędem.

Wyróżnia się trzy podstawowe typy klasyfikacji:

- **Klasyfikacja binarna** - problem dwuklasowy, w którym $K = 2$. Przykładem jest wykrywanie obecności lub braku choroby (tak/nie).
- **Klasyfikacja wieloklasowa** - problem, w którym obiekt jest przypisywany do jednej z wielu możliwych klas, czyli $K > 2$, np. stopnie zaawansowania choroby.
- **Klasyfikacja wieloetykietowa** - przypadek, gdy pojedyncza próbka może być jednocześnie przypisana do więcej niż jednej klasy, co formalnie można traktować jako przypisanie wektora etykiet $\mathbf{y} \in \{0, 1\}^K$.


W kontekście zadania klasyfikacji obrazów [11], dane wejściowe reprezentowane są w postaci tensora o strukturze przestrzennej odpowiadającej wymiarom wysokości i szerokości obrazu, uzupełnionego o wymiar kanałów kolorystycznych, takich jak przestrzeń barw RGB lub jej warianty. Taka reprezentacja cechuje się bardzo wysokim wymiarem, co implikuje znaczną złożoność przetwarzanych informacji. Ponadto, wartości pikseli nie są niezależne - ich wzajemne relacje są złożone, nieliniowe i często kontekstowo powiązane, co wpływa na kształtowanie się charakterystycznych wzorców potrzebnych do prawidłowego przypisania próbki do odpowiedniej klasy. Wyzwania związane z klasyfikacją obrazów obejmują konieczność efektywnego wydobycia reprezentacji cech na różnych poziomach abstrakcji - od detekcji prostych struktur krawędziowych i tekstur, aż po złożone wzorce semantyczne. Równocześnie, metody klasyfikacyjne muszą wykazywać odporność na różnorodne zakłócenia występujące w danych obrazowych, takie jak szумы losowe, zmiany warunków oświetleniowych, różnice w kątach i perspektywach rejestracji obrazu, a także różnorodność i niejednorodność danych wejściowych, która wynika z ograniczonej dostępności oraz heterogeniczności zbiorów danych medycznych.

2.3. Wykorzystanie głębokich sieci w analizie obrazów medycznych

Współczesne metody przetwarzania i interpretacji danych wizualnych przechodzą rewolucję za sprawą rozwoju architektur głębokiego uczenia [12], a w szczególności głębokich sieci neuronowych [13, 14]. **Uczenie głębokie** (ang. *deep learning*) jest podkategorią uczenia maszynowego, która opiera się na modelowaniu danych za pomocą wielowarstwowych sieci neuronowych. Sieci te składają się z hierarchicznie ułożonych warstw neuronów, które transformują dane wejściowe przez kolejne etapy abstrakcji, umożliwiając automatyczne wydobywanie coraz bardziej złożonych i reprezentatywnych cech. Dzięki głębokiej architekturze, modele te potrafią efektywnie reprezentować złożone zależności nieliniowe w danych, co stanowi kluczową przewagę nad tradycyjnymi metodami uczenia maszynowego, które opierają się na ręcznie konstruowanych lub ograniczonych zestawach cech. Podejście to, na przestrzeni ostatnich lat, zyskało na znaczeniu w

dziedzinie analizy obrazów, oferując narzędzia zdolne do ekstrakcji i interpretacji informacji na poziomie nieosiągalnym dla klasycznych algorytmów opartych na ręcznie definiowanych cechach.

Sztuczna sieć neuronowa (ang. *Artificial Neural Network*, ANN) [10] to rodzaj algorytmu uczenia maszynowego, którego konstrukcja oparta jest na obserwacjach funkcjonowania biologicznego układu nerwowego. W ANN każdy węzeł przekazuje sygnały do innych węzłów za pomocą połączeń, którym przypisane są wagi. Wagi te determinują, jak silnie sygnał z jednego neuronu wpływa na kolejny - wyższa waga oznacza większy wpływ. Podobnie jak w biologicznych neuronach, gdzie połączenia mogą wzmacniać się w wyniku współaktywności, w ANN proces uczenia polega na dostosowywaniu tych wag, aby sieć mogła skuteczniej rozwiązywać dany problem. Perceptron [15] to podstawowy algorytm klasyfikacji, który przyjmuje zestaw cech oraz odpowiadające im klasy, a następnie stara się odnaleźć płaszczyznę najlepiej oddzielającą różne klasy w przestrzeni cech. Perceptron można przyrównać do regresji logistycznej [16], która w podobny sposób rozdziela klasy, lecz wykorzystuje probabilistyczne podejście oparte na funkcji sigmoidalnej, zamiast progu jak perceptron. Gdy wiele perceptronów zostaje połączonych ze sobą, powstaje bardziej złożony model, znany jako wielowarstwowy perceptron (ang. *Multilayer Perceptron*, MLP) [11]. Składa się on z warstwy wejściowej, warstw ukrytych (jednej lub więcej) oraz warstwy wyjściowej. Na Rysunku 2.1, znajdującym się poniżej, ukazano przykład struktury MLP.




Rys. 2.1: Przykład struktury MLP. Źródło: Chen i in., analiza algorytmów klasyfikacji obrazów opartych na CNN [11].

Struktura MLP obejmuje warstwę wejściową składającą się z n neuronów oraz warstwę wyjściową zawierającą m neuronów, pomiędzy którymi znajduje się k neuronów w warstwach ukrytych. Każdy neuron warstwy ukrytej odbiera sygnały z neuronów warstwy poprzedniej, przetwarza je za pomocą ważonej sumy oraz funkcji aktywacji, a następnie przekazuje wynik do kolejnej warstwy.

Głębokie sieci neuronowe [10, 17] (ang. *Deep Neural Networks*, DNN) to rozwinięcie klasycznych sieci neuronowych, które wyróżniają się nie tylko znaczną liczbą warstw, ale przede wszystkim zdolnością do automatycznego uczenia się złożonych, hierarchicznych reprezentacji danych. To pogłębienie architektury umożliwia modelom wydobywanie coraz bardziej abstrakcyjnych i semantycznych cech, co znacznie poprawia ich skuteczność w zadaniach takich jak analiza obrazów czy rozpoznawanie wzorców. W szczególności, **konwulucyjne sieci neuronowe** [11] (ang. *Convolutional Neural Networks*, CNN) wyznaczyły nowy kierunek


w dziedzinie analizy obrazów, ze względu na swoją zdolność do efektywnego modelowania przestrzennych zależności i lokalnych wzorców w danych obrazowych. Na rysunku 2.2, przedstawiono ogólną architekturę konwolucyjnej sieci neuronowej.



Rys. 2.2: Architektura konwolucyjnej sieci neuronowej. Źródło: Wang i in., analiza zastosowań głębokiego uczenia w obrazach medycznych [17].

Podstawowym elementem tych sieci są warstwy konwolucyjne [17], które stosują specjalistyczne filtry służące do ekstrakcji cech z danych wejściowych. Warstwy te tworzą hierarchiczną strukturę, w której kolejne poziomy przetwarzania wyłaniają coraz bardziej abstrakcyjne reprezentacje obrazu. Na najniższym poziomie sieć uczy się rozpoznawać proste wzorce, takie jak krawędzie czy kontrasty kolorystyczne. Kolejne warstwy łączą te podstawowe elementy w bardziej skomplikowane struktury, np. narożniki lub łuki. W dalszych etapach sieć identyfikuje charakterystyczne fragmenty obiektów, takie jak oczy, nos czy usta, a następnie na ich podstawie rozpoznaje całe obiekty, np. twarze lub zwierzęta. Aby ograniczyć wymiarowość danych i zmniejszyć złożoność obliczeniową, w CNN stosuje się warstwy poolingowe. Najczęściej wykorzystuje się pooling maksymalny, który wybiera najwyższą wartość w danym regionie wejściowym, co pozwala na skuteczne redukcję rozmiaru map cech, zachowując jednocześnie istotne informacje. Takie podejście, wyróżniające się zdolnością do automatycznego dobierania i dostosowywania parametrów filtrów podczas procesu uczenia, eliminuje konieczność ręcznej ekstrakcji cech, która w klasycznych metodach stanowiła często wąskie gardło skuteczności. Proces ten odbywa się na podstawie optymalizacji funkcji kosztu, zwykle wykorzystującej algorytm propagacji wstecznej i gradientu, co umożliwia stopniową adaptację parametrów sieci do charakterystyki analizowanych danych.

Dodatkowo rozwój **uczenia transferowego** (ang. *transfer learning*) [8, 7] umożliwił istotne skrócenie czasu trenowania modeli oraz znaczącą poprawę ich efektywności, szczególnie w sytuacjach, gdy dostęp do obszernych i zróżnicowanych zbiorów danych jest ograniczony lub kosztowny do pozyskania. Dzięki możliwości przeniesienia wiedzy wyuczonej na dużych, reprezentatywnych zbiorach danych, uczenie transferowe pozwala na efektywne wykorzystanie istniejących modeli w nowych, często pokrewnych zadaniach, redukując tym samym wymogi dotyczące zasobów obliczeniowych oraz ilości danych treningowych niezbędnych do osiągnięcia zadowalającej jakości predykcji. Uczenie transferowe polega na adaptacji reprezentacji i wzorców wyuczonych przez model na zadaniu źródłowym, które posiada relację z zadaniem docelowym, do efektywnego rozwiązania tego ostatniego. W kontekście analizy obrazów, ta technika jest szczególnie efektywna przy wykorzystaniu rozbudowanych, głębokich sieci neuronowych, które zostały uprzednio wytrenowane na bardzo dużych i różnorodnych zbiorach danych. Wykorzystanie tych uprzednio wyuczonych wag umożliwia znaczące przyspieszenie procesu



Rys. 2.3: Grafika obrazująca uczenie transferowe. Źródło: Feng i in., analiza adaptacyjnego dostrajania transferowego na podstawie wielu domen [18].

uczenia, ponieważ model nie musi zaczynać od losowych parametrów, a jedynie dostosowuje już istniejące, ogólne reprezentacje do specyfiki problemu docelowego (tzw. *fine-tuning*).

W praktyce istnieje kilka podstawowych strategii uczenia transferowego. Jedną z nich jest wykorzystanie modelu jako ekstraktora cech - w takim podejściu wagi warstw odpowiedzialnych za ekstrakcję reprezentacji pozostają zamrożone (nie są modyfikowane podczas treningu na danych docelowych), natomiast trenowaniu poddawane są wyłącznie warstwy końcowe, które odpowiadają za mapowanie cech na konkretne etykiety klas lub wartości regresyjne. Takie podejście jest szczególnie korzystne w sytuacjach, gdy ilość danych docelowych jest niewielka, co ogranicza ryzyko przeuczenia modelu i umożliwia szybsze uzyskanie dobrych rezultatów bez konieczności kosztownego i długotrwałego treningu całej architektury.

Alternatywnie, gdy dostępny jest większy zbiór danych zbliżonych charakterem do danych źródłowych, stosuje się tzw. pełne dostrajanie (full fine-tuning), czyli rozmrożenie wszystkich lub większości warstw sieci i kontynuowanie treningu na danych docelowych. Ta metoda pozwala na głębszą adaptację modelu do specyficznych cech nowej domeny, umożliwiając modyfikację reprezentacji cech na poziomie niskopoziomowym i średniopoziomowym, co może znacząco podnieść efektywność predykcji. Jednocześnie wymaga to większych zasobów obliczeniowych i bardziej rozbudowanych zbiorów danych, aby uniknąć zjawiska przeuczenia.

Warto jednak zauważyć, że uczenie transferowe nie jest uniwersalnym rozwiązaniem. W przypadku znacznych różnic pomiędzy domeną zadania źródłowego a docelowego, może dojść do tzw. negatywnego transferu (ang. *negative transfer*) [19] - sytuacji, w której przeniesienie wcześniej wyuczonych wag i reprezentacji pogarsza wyniki modelu zamiast je poprawiać. W takich przypadkach bardziej efektywne może być trenowanie modelu od podstaw na danych specyficznych dla nowego problemu. Ponadto, gdy modele są stosunkowo proste lub zbiory danych niewielkie i proste, korzyści płynące z zastosowania uczenia transferowego mogą być ograniczone, co wymaga indywidualnej oceny opłacalności takiego podejścia.

W kontekście analizy obrazów medycznych, gdzie często występuje problem ograniczonej liczby oznaczonych próbek oraz duża złożoność danych, uczenie transferowe stanowi jedno z kluczowych narzędzi pozwalających na efektywne wykorzystanie potencjału głębokich sieci neuronowych. Technika ta minimalizuje ryzyko nadmiernego dopasowania, skraca czas treningu oraz pozwala na lepszą generalizację modeli na nowe przypadki kliniczne, co ma fundamentalne znaczenie w praktycznych zastosowaniach diagnostycznych i prognostycznych.

2.4. Modele głębokiego uczenia

Dobór architektury modelu głębokiego uczenia ma bezpośredni wpływ na skuteczność klasyfikacji, szczególnie w zadaniach o wysokim poziomie złożoności. Różnice między poszczególnymi modelami dotyczą m.in. sposobu przetwarzania danych, metod reprezentacji cech czy ogólnej zdolności do generalizacji. W zależności od zastosowanej koncepcji czy to klasycznych operacji konwolucyjnych, mechanizmów samo-uwagi, czy rozwiązań hybrydowych – modele te mogą w istotny sposób różnić się pod względem działania i osiąganego wydajności.

2.4.1. RetFound MAE

MAE (Masked Autoencoders) [20] to architektura zaproponowana przez zespół badaczy z Facebook AI Research (FAIR), która polega na rekonstrukcji brakujących fragmentów obrazu. Model uczy się wewnętrznej reprezentacji danych obrazowych poprzez maskowanie znacznej części obrazu wejściowego, a następnie próbuje go zrekonstruować. Model MAE oparty jest na architekturze Vision Transformer (ViT), co oznacza, że zamiast klasycznej konwolucji, obraz jest dzielony na patche i przetwarzany sekwencyjnie przez warstwy typu self-attention. W niniejszej pracy wykorzystano model **RetFound MAE** [21], bazujący na architekturze MAE. Jest to model bazowy (ang. *foundation model*) zaprojektowany specjalnie do ogólnego wykrywania chorób na podstawie obrazów dna oka. Został opracowany w celu zwiększenia uogólnialności i skuteczności systemów diagnostycznych działających na danych medycznych, szczególnie w kontekście szerokiego spektrum schorzeń okulistycznych. RetFound bazuje na głębokich sieciach neuronowych i jest trenowany na dużych, zróżnicowanych zbiorach obrazów siatkówki, co pozwala mu na lepsze wychwycenie charakterystycznych cech chorób siatkówki. Wprowadzona w projekcie wersja RetFoundMAE [22] łączy potencjał Masked Autoencoders (MAE) z architekturą RetFound, wykorzystując technikę samonadzorowanego uczenia przez maskowanie fragmentów obrazu oraz rekonstrukcję. Dzięki temu model uczy się efektywnych reprezentacji obrazów siatkówki nawet z niepełnych danych wejściowych, co poprawia jego odporność na szumy oraz różnorodność danych obrazowych. RetFoundMAE jest więc rozszerzeniem RetFound o mechanizmy pozwalające na lepsze wykorzystanie dostępnych informacji i zwiększenie generalizacji modelu. Poniżej przedstawiono obrazowo działanie modelu RETFound.

2.4.2. MedViT

Vision Transformer (ViT) [23] to architektura sieci neuronowej oparta na mechanizmie transformera, pierwotnie zaprojektowana do przetwarzania sekwencji w zadaniach NLP, która została zaadaptowana do analizy obrazów. Zamiast klasycznych warstw konwolucyjnych, ViT dzieli obraz na mniejsze, równe fragmenty (tzw. *patch'e*), które są następnie liniowo mapowane na wektory cech i podawane do warstw transformera. Transformer, dzięki mechanizmowi uwagi, potrafi efektywnie uchwycić zależności między różnymi fragmentami obrazu, co pozwala na lepszą reprezentację kontekstową i globalny ogłód sceny. ViT wyróżnia się skalowalnością oraz możliwością uczenia na bardzo dużych zbiorach danych, co przekłada się na wysoką skuteczność w zadaniach klasyfikacji obrazów. **MedVit** [24] to wariant Vision Transformera specjalnie dostosowany do analizy medycznych obrazów 3D oraz 2D, takich jak obrazy siatkówki czy tomografie. Model ten integruje architekturę transformera z mechanizmami specyficznymi dla danych medycznych, na przykład uwzględnia hierarchiczne reprezentacje przestrzenne oraz lokalne i globalne zależności w obrazie. MedVit jest zoptymalizowany do pracy z ograniczonymi i hałaśliwymi danymi medycznymi, wykorzystując strategie takie jak transfer learning i samonadzorowane uczenie, co umożliwia mu efektywne rozpoznawanie wzorców chorobowych i zwiększa jego odporność na różnorodność danych klinicznych. Model ten został pretrenowany na

dużych zbiorach obrazów medycznych, takich jak ChestXray14, EyePACS oraz innych publicznie dostępnych zbiorach. Dzięki temu wykazuje się lepszymi właściwościami w zakresie transferu wiedzy między różnymi dziedzinami diagnostyki obrazowej.

2.4.3. Swin Transformers

Swin Transformer (Shifted Window Transformer) [25, 26] to hierarchiczna architektura z rodziny Vision Transformerów, opracowana w celu efektywnego przetwarzania obrazów o wysokiej rozdzielczości przy zredukowanym koszcie obliczeniowym. W przeciwieństwie do pierwotnego wariantu Vision Transformera (ViT), który wykorzystuje globalną segmentację obrazu na niezmiennie fragmenty (*patches*) i przetwarza je z pominięciem lokalnej struktury, Swin Transformer implementuje mechanizm przesuwanych okien (*shifted windows*). Pozwala to na lokalne modelowanie zależności w ograniczonych przestrzennie regionach, z zachowaniem kontekstualnej spójności pomiędzy sąsiadującymi oknami.

Architektura Swin Transformera budowana jest w sposób hierarchiczny, co oznacza, że reprezentacje są konstruowane z wykorzystaniem kolejnych warstw agregujących informacje z coraz szerszych obszarów obrazu. Takie podejście umożliwia efektywne skalowanie modelu oraz redukuje złożoność obliczeniową względem pełnej uwagi w przestrzeni globalnej. Ponadto, wykorzystanie lokalnej samo-atencji w połączeniu z przesunięciami okien zapewnia lepsze uogólnienie na danych o nieregularnej strukturze oraz wspiera zachowanie spójności semantycznej w przypadku obrazów o zróżnicowanej rozdzielczości.

2.4.4. ResNet50

ResNet-50 (Residual Network, 50 warstw) [27] stanowi głęboką architekturę konwolucyjną zaprojektowaną z wykorzystaniem mechanizmu propagacji resztkowej, który umożliwia skuteczne trenowanie bardzo głębokich sieci neuronowych poprzez minimalizację problemu zanikającego gradientu. Struktura modelu opiera się na wprowadzeniu tzw. *residual blocks*, czyli bloków z połączeniami skrótowymi (ang. *shortcut connections*), które realizują tożsamościowe odwzorowania danych wejściowych. Model ResNet-50 składa się z 50 warstw obliczeniowych, zorganizowanych w sekwencję bloków resztkowych zawierających po trzy warstwy konwolucyjne typu bottleneck. Takie podejście umożliwia redukcję liczby parametrów oraz zwiększenie efektywności obliczeniowej przy zachowaniu głębokości modelu. Architekturę rozpoczyna pojedyncza warstwa konwolucyjna o dużym rozmiarze jądra, po której następują warstwa normalizacji oraz operacja maksymalnego próbkowania. Dalsze etapy przetwarzania realizowane są przez cztery złożone bloki resztkowe o rosnącej liczbie kanałów i malejącej rozdzielczości reprezentacji przestrzennej. Zastosowanie połączeń resztkowych umożliwia przekazywanie informacji bezpośrednio przez kolejne warstwy, co przyczynia się do zachowania stabilności gradientu podczas uczenia i poprawy dokładności klasyfikacyjnej w zadaniach wizji komputerowej. Model ResNet-50 jest wstępnie trenowany na zbiorze danych ImageNet - konkretnie ImageNet-1k, który zawiera około 1,2 miliona obrazów przypisanych do 1000 klas.

2.5. Przegląd istniejących metod diagnostyki retinopatii cukrzycowej

Istnieje wiele artykułów naukowych, które koncentrują się na zadaniu diagnostyki retinopatii cukrzycowej, wykorzystując techniki głębokiego uczenia. Praca autorstwa Wejdan L. i in. [28] koncentruje się na przeglądzie metod wykorzystywanych do automatycznego wykrywania i klasyfikacji retinopatii cukrzycowej. Autorzy przedstawili różne podejścia - binarne oraz

wieloklasowe. Jednym z nich jest badanie K. Xu. i in. [29, 28], w którym autorzy podzielił zbiór danych na dwie klasy - obrazy prawidłowe (brak retinopatii) oraz takich, na których widoczne są anomalie charakterystyczne dla retinopatii cukrzycowej. W badaniu wykorzystano próbkę obejmującą 1000 zdjęć siatkówki. Przed przetwarzaniem obrazy poddano przygotowaniu obejmującemu zmianę rozdzielczości do wymiarów $224 \times 224 \times 3$ oraz rozszerzenie zbioru za pomocą technik przekształceń geometrycznych. Do klasyfikacji zastosowano konwolucyjną sieć neuronową złożoną z ośmiu warstw konwolucyjnych, czterech warstw maksymalnego próbkowania oraz dwóch warstw w pełni połączonych. W warstwie końcowej zastosowano funkcję aktywacji umożliwiającą przypisanie obrazu do jednej z dwóch kategorii. Zaproponowane rozwiązanie osiągnęło wysoką skuteczność, gdzie dokładność klasyfikacji wyniosła 94,5%, co wskazuje na dużą trafność modelu przy rozróżnianiu przypadków zdrowych od patologicznych.

W badaniu przeprowadzonym przez V. Gulshana i in. [30, 28] opracowano podejście wykorzystujące konwolucyjne sieci neuronowe do rozpoznawania retinopatii cukrzycowej oraz obrzęku plamki żółtej związanego z cukrzycą. W celu przetestowania modelu zastosowano dwa zbiory danych: Messidor-2 oraz EyePACS-1. Przed wprowadzeniem do sieci dane zostały poddane normalizacji, a średnica obrazu została przeskalowana do szerokości 299 pikseli, zgodnie z wymaganiami wybranej architektury. Zastosowano dziesięć sieci neuronowych bazujących na wcześniej wytrenowanym modelu Inception-v3. Każda z tych sieci była uczona na zbiorach o różnej liczbie przykładów, a końcową decyzję diagnostyczną uzyskiwano przez uśrednienie wyników poszczególnych modeli za pomocą funkcji liniowej. Ostateczna klasyfikacja obejmowała obrazy możliwe do oceny oraz takie, które spełniały kryteria rozpoznania obrzęku plamki, retinopatii cukrzycowej od stadium umiarkowanego wzwyż, a także stadium ciężkiego i wyższego. Model uzyskał wysoką skuteczność diagnostyczną - czułość na poziomie 96,1% (Messidor-2) i 97,5% (EyePACS-1) oraz specyficzność wynoszącą 93% w obu zbiorach. Warto jednak zaznaczyć, że metodologia nie obejmowała jednoznacznego rozróżnienia obrazów bez zmian chorobowych ani klasyfikacji według pięciostopniowej skali retinopatii cukrzycowej.

W analizie przeprowadzonej przez X. Wanga [31, 28] i in. porównano skuteczność trzech dostępnych, wstępnie wytrenowanych architektur sieci konwolucyjnych: VGG16, AlexNet oraz InceptionNet V3 w zadaniu klasyfikacji obrazów siatkówki zgodnie z pięciostopniową skalą retinopatii cukrzycowej. Badanie przeprowadzono na zbiorze Kaggle, ograniczonym do 166 obrazów. Na etapie wstępnego przetwarzania dane wejściowe zostały przeskalowane do rozdzielczości zgodnych z wymaganiami poszczególnych modeli: 224×224 piksele dla VGG16, 227×227 dla AlexNet oraz 299×299 dla InceptionNet V3. Mimo wykorzystania zaawansowanych architektur, uzyskane wyniki były ograniczone - średnia dokładność klasyfikacji wyniosła odpowiednio 50,03% dla VGG16, 37,43% dla AlexNet oraz 63,23% dla InceptionNet V3. Należy podkreślić, że ograniczona liczba przykładów w zbiorze danych istotnie wpłynęła na możliwości modeli w zakresie nauki reprezentatywnych cech. Dodatkowym ograniczeniem był brak rozbudowanych procedur wstępnej obróbki obrazu oraz wykorzystanie jedynie jednego zbioru danych do oceny skuteczności proponowanego podejścia.

W badaniu autorstwa Mobeen-ur-Rehmana [32, 28] i in. wykorzystano zarówno własną architekturę sieci konwolucyjnej, jak i wcześniej wytrenowane modele, takie jak AlexNet, VGG-16 oraz SqueezeNet- do klasyfikacji stopni zaawansowania retinopatii cukrzycowej w zbiorze MES-SIDOR. Zbiór ten zawiera 1200 obrazów podzielonych na cztery kategorie odpowiadające różnym etapom choroby. W ramach wstępnego przetwarzania obrazy zostały wykadrowane, przeskalowane do ustalonej rozdzielczości 244×244 piksele, a następnie poddane wzmocnieniu kontrastu przy użyciu metody wyrównywania histogramu. Opracowana przez autorów architektura sieci składała się z pięciu warstw, w tym dwóch konwolucyjnych, dwóch

warstw spoolingujących typu max-pooling oraz trzech warstw w pełni połączonych. Najwyższe rezultaty uzyskano przy zastosowaniu autorskiej sieci: dokładność klasyfikacji osiągnęła poziom 98,15%, czułość wyniosła 98,94%, a swoistość 97,87%. AlexNet, VGG-16 oraz SqueezeNet uzyskały dokładność klasyfikacji na poziomie odpowiednio 93,46%, 91,82% oraz 94,49%.

2.6. Metody ewaluacji

2.6.1. Walidacja krzyżowa

W procesie trenowania oraz ewaluacji modeli kluczową rolę odgrywa zastosowanie **walidacji krzyżowej** [33], będącej jedną z podstawowych technik oceny jakości modeli uczenia maszynowego. Jej celem jest uzyskanie bardziej wiarygodnych i stabilnych wyników w porównaniu do pojedynczego, statycznego podziału danych na zestawy treningowe i testowe. Metoda ta polega na podziale całego zbioru danych na k wzajemnie wykluczających się podzbiorów (tzw. foldów). Model jest trenowany k razy - za każdym razem na $k-1$ foldach, a pozostały fold służy do walidacji, czyli oceny jego wydajności. Ostateczna ocena modelu powstaje jako średnia wyników ze wszystkich iteracji. Takie podejście pozwala na pełniejsze wykorzystanie dostępnych danych, ponieważ każda próbka jest używana zarówno do trenowania, jak i do testowania modelu, co redukuje ryzyko nadmiernego dopasowania do konkretnego podziału danych oraz minimalizuje wpływ losowego rozkładu próbek na uzyskane rezultaty.

Walidacja krzyżowa jest szczególnie ważna w sytuacjach, gdy dysponujemy ograniczoną ilością danych treningowych, gdyż w takich przypadkach każdy przykład ma istotne znaczenie dla jakości i stabilności modelu. Tradycyjny podział danych na zestawy treningowe i testowe może skutkować dużą wariancją wyników, spowodowaną losowym charakterem tego podziału, co utrudnia rzetelną ocenę efektywności modelu. Walidacja krzyżowa minimalizuje ten problem, umożliwiając wielokrotne trenowanie i testowanie modelu na różnych podzbiorach, dzięki czemu uzyskujemy bardziej wiarygodne i uśrednione wyniki.

W przypadku dużych zbiorów danych, gdzie dostępna liczba próbek jest znacząca, klasyczny podział danych na zbiór treningowy i walidacyjny (np. w proporcji 80/20) często pozwala na uzyskanie stabilnych i reprezentatywnych wyników, ponieważ duża liczba przykładów redukuje ryzyko nadmiernego dopasowania do konkretnego podziału danych. W takich przypadkach zastosowanie pełnej walidacji krzyżowej (np. k -fold) może nie przynieść istotnie lepszej oceny modelu, natomiast znacząco zwiększa czas obliczeń, co bywa nieefektywne przy skomplikowanych modelach i dużych zbiorach.

2.6.2. Metryki ewaluacji skuteczności klasyfikacji

W celu kompleksowej oceny skuteczności klasyfikacji stopnia zaawansowania retinopatii cukrzycowej zastosowano szereg miar ewaluacyjnych, umożliwiających szczegółową analizę jakości predykcji generowanych przez poszczególne modele. Choć metryki te zostały szczegółowo omówione w pracy Tervena i in. [34], niniejszy rozdział przedstawia wybrane z nich, istotne z punktu widzenia zastosowań praktycznych oraz charakterystyki analizowanego problemu.

Balanced Accuracy (Zrównoważona Dokładność) Miara skuteczności klasyfikatora, która jest szczególnie przydatna w przypadku niebalansowanych zbiorów danych. W odróżnieniu od klasycznej dokładności (accuracy), która może być zawyżona przez dominujące klasy, balanced accuracy obliczana jest jako średnia czułość dla każdej klasy.

$$\text{Balanced Accuracy} = \frac{1}{C} \sum_{i=1}^C \frac{TP_i}{TP_i + FN_i} \quad (2.1)$$

gdzie:

- N – liczba klas,
- TP_i – liczba prawidłowo sklasyfikowanych przykładów klasy i (True Positives),
- FN_i – liczba przykładów klasy i , które zostały błędnie zaklasyfikowane jako inna klasa (False Negatives).

Im wyższa wartość zrównoważonej dokładności, tym lepsza jest ogólna wydajność klasyfikatora w kontekście równomiernego rozpoznawania wszystkich klas.

Precision (Precyzja) Miara określająca dokładność pozytywnych predykcji modelu. W kontekście klasyfikacji binarnej, precyzja wyraża stosunek liczby prawdziwie pozytywnych wyników (TP) do sumy wszystkich przykładów, które model oznaczył jako pozytywne, czyli prawdziwych pozytywów i fałszywych pozytywów (FP).

$$\text{Precision} = \frac{TP}{TP + FP} \quad (2.2)$$

gdzie:

- TP — liczba prawdziwych pozytywów, czyli przypadków, w których model prawidłowo zaklasyfikował przykład jako pozytywny;
- FP — liczba fałszywych pozytywów, czyli sytuacji, gdy model błędnie uznał negatywny przypadek za pozytywny.

W przypadku klasyfikacji wieloklasowej, gdzie mamy N klas, precyzję można obliczyć dla każdej klasy osobno, traktując daną klasę jako pozytywną, a pozostałe jako negatywne. Następnie, aby uzyskać ogólną miarę precyzji, stosuje się uśrednianie. Jednym z najczęściej używanych podejść jest macro-średnia precyzji, która przypisuje jednakową wagę wszystkim klasom, niezależnie od ich liczebności:

$$\text{Macro-Precision} = \frac{1}{N} \sum_{i=1}^N \frac{TP_i}{TP_i + FP_i} \quad (2.3)$$

Wysoka wartość precyzji oznacza, że model rzadko się myli, jeśli już stwierdzi, że coś należy do danej klasy.

Recall (Czułość) Wskaźnik prawdziwych pozytywów określa zdolność modelu do wykrywania rzeczywistych pozytywnych przypadków. W klasyfikacji binarnej, recall to stosunek liczby prawdziwie wykrytych pozytywów (TP) do wszystkich rzeczywistych pozytywów, czyli sumy prawdziwych pozytywów i fałszywych negatywów (FN).

$$\text{Recall} = \frac{TP}{TP + FN}, \quad (2.4)$$

gdzie:

- TP to liczba prawidłowo zaklasyfikowanych przykładów pozytywnych,
- FN to liczba przykładów pozytywnych błędnie sklasyfikowanych jako negatywne.

W przypadku klasyfikacji wieloklasowej recall należy obliczyć oddzielnie dla każdej klasy, traktując ją kolejno jako pozytywną, a pozostałe jako negatywne. Aby uzyskać uogólniony wskaźnik dla całego modelu, stosuje się średnią macro, która traktuje każdą klasę jednakowo, niezależnie od jej częstości:

$$\text{Macro-Recall} = \frac{1}{N} \sum_{i=1}^N \frac{TP_i}{TP_i + FN_i}, \quad (2.5)$$

gdzie:

- TP_i oraz FN_i oznaczają odpowiednio liczbę prawdziwych pozytywów i fałszywych negatywów dla klasy i ,
- N to liczba klas.

Wysoka wartość recall oznacza, że model skutecznie identyfikuje większość rzeczywistych pozytywów, co jest szczególnie istotne w zastosowaniach, gdzie pominięcie pozytywnego przypadku może mieć poważne konsekwencje (np. w diagnostyce medycznej).

F1 Score Miarą statystyczna łączącą w sobie informacje zarówno o precyzji, jak i czułości, tworząc pojedynczy wskaźnik oceny efektywności modelu klasyfikacyjnego. Definiuje się go jako średnią harmoniczną precyzji i czułości:

$$F1 = 2 \cdot \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}. \quad (2.6)$$

Średnia harmoniczna powoduje, że F1-score karze model za duże różnice pomiędzy Precision a Recall, dzięki czemu oba te aspekty muszą być na wysokim poziomie, aby wynik F1 był wysoki. Wysoki F1-score świadczy o tym, że klasyfikator jest dobrze zbalansowany - potrafi zarówno trafnie wykrywać pozytywne przypadki (wysoki Recall), jak i unikać nadmiernych fałszywych alarmów (wysoki Precision).

Specificity Wskaźnik prawdziwie negatywnych, określa odsetek rzeczywistych negatywnych próbek, które zostały prawidłowo zaklasyfikowane jako negatywne przez model. W kontekście klasyfikacji binarnej, specificity definiuje się wzorem:

$$\text{Specificity} = \frac{TN}{TN + FP}, \quad (2.7)$$

gdzie TN oznacza liczbę prawdziwych negatywów, czyli przypadków, które model poprawnie rozpoznał jako negatywne, a FP to liczba fałszywych pozytywów, czyli przykładów błędnie sklasyfikowanych jako pozytywne pomimo bycia negatywnymi.

Wysoka wartość specificity świadczy o tym, że model skutecznie unika fałszywych alarmów, co jest szczególnie istotne w sytuacjach, gdzie błędne zaklasyfikowanie negatywnych przykładów jako pozytywne niesie poważne konsekwencje.

ROC AUC Metryka służąca do oceny skuteczności klasyfikatora binarnego w kontekście różnych progów decyzyjnych. Wartość AUC (Area Under the Curve) reprezentuje pole pod krzywą ROC (Receiver Operating Characteristic), która obrazuje zależność pomiędzy True Positive Rate (TPR) a False Positive Rate (FPR) przy zmiennym progu klasyfikacji.

Wzór na FPR oraz TPR:

$$\text{TPR} = \frac{TP}{TP + FN}, \quad \text{FPR} = \frac{FP}{FP + TN} \quad (2.8)$$

Wysoka wartość ROC AUC (bliska 1) wskazuje na dobrą zdolność modelu do rozróżniania klas - model poprawnie przypisuje wyższe prawdopodobieństwa klasie pozytywnej niż negatywnej. Wartość 0,5 sugeruje losowe zgadywanie, natomiast wynik poniżej 0,5 może oznaczać, że model działa odwrotnie niż powinien.

Quadratic Weighted Kappa (QWK) [35] Miara zgodności pomiędzy dwiema ocenami porządkowymi (np. przypisanymi przez człowieka i przez model), uwzględniająca zarówno przypadkową zgodność, jak i odległość pomiędzy kategoriami. Jest szczególnie przydatna w problemach klasyfikacji porządkowej, gdzie kategorie mają naturalną kolejność, np. stopnie

choroby.

QWK obliczane jest jako:

$$\kappa = 1 - \frac{\sum_{i,j} w_{i,j} O_{i,j}}{\sum_{i,j} w_{i,j} E_{i,j}}, \quad (2.9)$$

gdzie:

- O to macierz obserwowanych częstości klasyfikacji (rzeczywiste vs przewidywane),
- E to oczekiwana częstość (przy założeniu losowej zgody),
- $w_{i,j}$ to wagi kar za niezgodność klas i i j — w przypadku kwadratowej wersji definiowane jako:

$$w_{i,j} = \frac{(i - j)^2}{(N - 1)^2},$$

gdzie N to liczba kategorii.

QWK przyjmuje wartości w przedziale $[-1, 1]$, gdzie 1 oznacza pełną zgodność, 0 – zgodność losową, a wartości ujemne wskazują na gorszą niż losowa zgodność.

2.6.3. Metryki ewaluacji zdolności do transferu wiedzy

W celu oceny wpływu wcześniej wytrenowanego modelu na efektywność rozwiązywania nowego, powiązanego zadania, stosuje się wyspecjalizowane metryki służące do analizy zdolności modeli do transferu wiedzy.

TransRate [36] Miara służąca do ilościowej oceny jakości reprezentacji cech wygenerowanych przez model. Opiera się na założeniu, że dobre reprezentacje powinny maksymalizować odległość pomiędzy centrami klas przy jednoczesnej minimalizacji rozrzutu wewnątrzklasowego. Im wyższa wartość, tym lepsze skupienie próbek tej samej klasy w przestrzeni cech oraz większa separacja między klasami. Implementacje zaprezentowano w artykule [36] autorstwa Long-Kai Huang i in.

Listing 2.1: Implementacja TransRate zaproponowana w artykule

```
import numpy as np

def coding_rate(Z, eps=1e-4):
    n, d = Z.shape
    _, rate = np.linalg.slogdet(np.eye(d) + 1 / (n * eps) * Z.T @ Z)
    return 0.5 * rate

def transrate(Z, y, eps=1e-4):
    Z = Z - np.mean(Z, axis=0, keepdims=True)
    RZ = coding_rate(Z, eps)
    RZY = 0.0
    K = int(y.max()) + 1
    for i in range(K):
        class_samples = Z[y == i]
        RZY += coding_rate(class_samples, eps)
    return RZ - RZY / K
```

$$\text{TransRate}(Z, y) = R(Z) - \frac{1}{K} \sum_{i=1}^K R(Z_i) \quad (2.10)$$

LogME (*Logarithm of Marginal Evidence*) [37] Metryka oceniająca przydatność wyekstrahowanych cech do zadania klasyfikacji. Metoda ta mierzy logarytm marginalnego prawdopodobieństwa etykiet docelowych, warunkowanego osadzeniami cech, co pozwala na ocenę, jak dobrze cechy źródłowego modelu reprezentują dane docelowe bez konieczności trenowania dodatkowych modeli.

$$\text{LogME} = \log p(\mathbf{y} \mid \mathbf{X}, \theta) \quad (2.11)$$

LEEP (*Log Expected Empirical Prediction*) [38] Metryka oceniająca zgodność pomiędzy predykcjami modelu źródłowego a rzeczywistymi etykietami danych docelowych. Najpierw model źródłowy generuje pseudo-etykiety dla obrazów docelowych, które następnie służą do obliczenia logarytmu wiarygodności (ang. *log-likelihood*) pomiędzy tymi pseudo-etykietami a rzeczywistymi etykietami. Założenie przyjęte w metodzie jest takie, że jeśli predykcje modelu źródłowego skupiają się wyraźnie wokół poszczególnych etykiet zbioru docelowego, to adaptacja modelu do nowego zadania powinna przebiegać efektywniej.

$$\text{LEEP} = \sum_{i=1}^N \log \left(\sum_{k=1}^K p(y_i | z_k) p(z_k | x_i) \right) \quad (2.12)$$

NCE (*Noise Contrastive Estimation*) [39] Metoda estymacji parametrów modelu probabilistycznego, która zamienia problem estymacji rozkładu prawdopodobieństwa na zadanie klasyfikacji binarnej. Model uczy się odróżniać próbki pochodzące z rzeczywistego rozkładu danych od próbek generowanych przez rozkład szumu. Dzięki temu możliwe jest obejście problemu obliczania trudnego do wyliczenia normalizatora rozkładu.

$$\mathcal{L} = \sum_{i=1}^N \log \sigma(f(x_i)) + \sum_{j=1}^M \log (1 - \sigma(f(\tilde{x}_j))) \quad (2.13)$$

H-score Metryka oceniająca jakość separacji klas w przestrzeni reprezentacji wygenerowanej przez model. Oblicza się ją jako stosunek śladu macierzy kowariancji międzyklasowej do sumy śladów macierzy kowariancji międzyklasowej i wewnątrzklasowej. Wysoka wartość H-score wskazuje, że próbki należące do tej samej klasy tworzą zwarte skupiska, a różne klasy są dobrze od siebie odseparowane.

$$H = \frac{\text{Tr}(S_B)}{\text{Tr}(S_W) + \varepsilon} \quad (2.14)$$

LogDet Divergence Miara rozbieżności pomiędzy dwiema macierzami kowariancji, często wykorzystywana do oceny różnic w rozkładach cech reprezentujących różne klasy. W kontekście transfer learningu służy do oceny jakości wygenerowanej przestrzeni reprezentacji - im większa wartość LogDet Divergence, tym większe zróżnicowanie między rozkładami klas, co zwykle koreluje z lepszą rozdzielczością klas w embedding space. Formalnie jest to miara dywergencji oparta o logarytm wyznacznika macierzy, zachowująca niezmienniczość względem transformacji liniowych.

$$D_{\text{LogDet}}(A \parallel B) = \text{Tr}(AB^{-1}) - \log \det(A) + \log \det(B) - d \quad (2.15)$$

Transfer Gain Wzrost skuteczności klasyfikatora po zastosowaniu wstępnie wytrenowanego modelu w porównaniu do modelu trenowanego od podstaw. Wyrażany jest jako różnica dokładności

klasyfikacji w obu scenariuszach, a w wersji względnej jako procentowy przyrost względem modelu bazowego. Miara ta pozwala oszacować efektywność transferu wiedzy między zadaniem źródłowym a docelowym.

$$\text{TransferGain} = \frac{\text{Acc}_{\text{pretrained}} - \text{Acc}_{\text{scratch}}}{\text{Acc}_{\text{scratch}} + \varepsilon} \quad (2.16)$$

Few-shot Accuracy Metryka odzwierciedlająca skuteczność klasyfikatora w warunkach bardzo ograniczonej liczby próbek uczących. Jest ona używana do oceny zdolności modelu do generalizacji na podstawie niewielkiej ilości danych. Modele charakteryzujące się wysokim few-shot accuracy wykazują zdolność do szybkiego uczenia się nowych klas lub zadań na podstawie wcześniej przyswojonych reprezentacji ogólnych.

$$\text{Acc}_{k\text{-shot}} = \frac{1}{k} \sum_{i=1}^k 1(y_i = \hat{y}_i) \quad (2.17)$$

Learning Efficiency Tempo uczenia się modelu w zależności od liczby dostępnych próbek treningowych. Jest to funkcja zależności pomiędzy wielkością zbioru danych a osiąganą dokładnością klasyfikacji. Modele o wysokiej efektywności uczenia osiągają zadowalające rezultaty przy relatywnie małej liczbie przykładów. Metryka ta jest szczególnie istotna w scenariuszach few-shot learning lub uczenia niskozasobowego, gdzie dostęp do danych jest ograniczony.

$$\text{LearningEfficiency}(n) = \text{Accuracy}_n \quad (2.18)$$

2.6.4. Redukcja wymiarowości i wizualizacja danych

W celu lepszego zrozumienia struktury danych oraz ich reprezentacji w przestrzeni stosuje się techniki redukcji wymiarowości. Wysokowymiarowe dane, takie jak wektory osadzeń uzyskane z modelu, mogą stanowić problem w ich interpretacji. Z tego powodu częstą praktyką jest wykorzystanie metod, które pozwalają zamienić złożony, wielowymiarowy problem do postaci dwuwymiarowej przy zachowaniu jak największej ilości informacji w ich strukturze. Wizualizacja danych po redukcji wymiarowości umożliwia ocenę separowalności klas oraz jakość uzyskanych reprezentacji.

PCA (Principal Component Analysis) [40] Metoda redukcji wymiarowości przestrzeni danych, polegająca na znalezieniu ortonormalnej bazy, w której dane mają największą wariancję. PCA przekształca dane do przestrzeni o mniejszym wymiarze, przy zachowaniu jak największej ilości informacji (wariancji). W kontekście oceny jakości reprezentacji, PCA umożliwia wizualizację danych wysokowymiarowych i pozwala ocenić, czy próbki tworzą odseparowane klastry odpowiadające klasom etykiet.

t-SNE (t-distributed Stochastic Neighbor Embedding) [41] Nieliniowa metoda redukcji wymiarów, która konwertuje odległości euklidesowe w przestrzeni wysokowymiarowej na prawdopodobieństwa sąsiedztwa, a następnie odwzorowuje je w przestrzeni dwuwymiarowej lub trójwymiarowej. Metoda ta skupia się na zachowaniu lokalnych relacji między punktami, dzięki czemu jest szczególnie przydatna do wizualizacji struktur klasowych i klastrów. W analizie embeddingów t-SNE pozwala zobrazować strukturę przestrzeni reprezentacji i sprawdzić, czy dane z różnych klas tworzą rozłączne skupiska.

2.7. Metody wyjaśnialnej sztucznej inteligencji


Sztuczna inteligencja stała się integralnym elementem wielu współczesnych systemów, nie tylko w obszarze medycyny, ale również w przemyśle, finansach, edukacji czy administracji publicznej. Wraz ze wzrostem jej zastosowań, pojawiła się potrzeba zapewnienia transparentności i zrozumiałości podejmowanych przez nią decyzji. Kluczowe staje się zatem nie tylko to, co system decyduje, ale również dlaczego podejmuje daną decyzję. W odpowiedzi na tę potrzebę rozwinięto koncepcję **wyjaśnialnej sztucznej inteligencji** [42, 43] (ang. *Explainable Artificial Intelligence, XAI*), której celem jest umożliwienie użytkownikom, zarówno specjalistom, jak i osobom nietechnicznym, zrozumienia mechanizmów działania modeli AI. Przejrzystość oraz uczciwość systemów opartych na SI są warunkiem niezbędnym do budowania zaufania, a tym samym do ich szerokiego zastosowania i społecznej akceptacji. Modele, których decyzje są nieprzejrzyste, budzą obawy i mogą prowadzić do niepożądanych konsekwencji, zwłaszcza w kontekście krytycznych zastosowań, takich jak diagnostyka medyczna. Umożliwienie zrozumienia wewnętrznych procesów modelu pozwala nie tylko na ocenę poprawności i etyczności decyzji, lecz także na ich skuteczniejszą kontrolę, interpretację i dalszy rozwój. W literaturze zaproponowano szereg metod wspierających wyjaśnialność modeli, zarówno dla klasyfikatorów opartych na regułach, jak i dla bardziej złożonych sieci neuronowych. Wśród najczęściej stosowanych podejść wyróżnia się m.in. techniki oparte na ocenie istotności cech wejściowych, takich jak *SHapley Additive exPlanations* (SHAP), *Local Interpretable Model-agnostic Explanations* (LIME), metody wizualizacji aktywacji *Gradient-weighted Class Activation Mapping* (Grad-CAM) czy tworzenie uproszczonych modeli zastępczych (ang. *surrogate models*). Wybór odpowiedniej metody zależy od typu modelu, rodzaju danych oraz potrzeb końcowego użytkownika.

2.7.1. SHAP

SHAP [44] (*Shapley Additive Explanations*) jest metodą wyjaśniania predykcji modeli, która opiera się na koncepcji wartości Shapleya z teorii gier, pierwotnie opracowana jako miara sprawiedliwego podziału nagrody pomiędzy grupę graczy, którzy przyczynili się do określonego wyniku. Metoda ta dostarcza ilościowej oceny wpływu poszczególnych cech wejściowych na wynik modelu, zapewniając spójne ramy interpretowalności. Cechą charakterystyczną SHAP jest jego zgodność z aksjomatami pochodzącymi z teorii gier, takimi jak efektywność, symetria, bezczynność i addytywność.

W kontekście klasyfikacji obrazów, SHAP przekształca surowe dane wejściowe (np. piksele obrazu lub ich grupy) w zbiór cech, a następnie ocenia marginalny wkład każdej z tych cech w końcową decyzję modelu. Działa to poprzez porównanie przewidywań modelu przy różnych kombinacjach obecności i nieobecności poszczególnych cech, a następnie obliczenie uśrednionych różnic względem wszystkich możliwych permutacji cech. Wynikiem tego procesu jest przypisanie każdej cechy wartości SHAP, która kwantyfikuje jej wpływ na zmianę przewidywania względem wartości bazowej. W przypadku modeli przetwarzających obrazy, takich jak konwolucyjne sieci neuronowe, SHAP najczęściej działa w oparciu o zmodyfikowaną wersję tzw. Kernel SHAP lub Deep SHAP. W pierwszym przypadku wejściowy obraz jest dzielony na segmenty (superpiksele), a model testowany jest na wersjach obrazu z różnymi kombinacjami obecności/nieobecności segmentów. W drugim przypadku, Deep SHAP wykorzystuje strukturę warstwową sieci neuronowej, łącząc gradientowe podejścia z teorią wartości Shapleya, co pozwala na efektywne przybliżenie wkładu cech bez konieczności generowania wszystkich możliwych permutacji. Wyniki działania SHAP dla obrazów mogą być wizualizowane w postaci map cieplnych (tzw. heatmaps), w których kolory wskazują pozytywny lub negatywny wpływ określonych fragmentów obrazu na klasyfikację. Takie wizualizacje

pozwalają badaczom oraz użytkownikom końcowym na ocenę zgodności działania modelu z wiedzą dziedzinową oraz wykrywanie potencjalnych błędów, uprzedzeń lub nieoczekiwanych zależności wykorzystywanych przez model. Na Rysunku 2.4 przedstawiono działanie metody SHAP na przykładzie diagnozy raka płuc [45].




Rys. 2.4: Wizualizacja działania metody SHAP na przykładzie wykrywania stopnia zaawansowania raka płuc. Źródło: Nahiduzzaman i in. [45].

Przewaga czerwonych pikseli na obrazie SHAP wskazuje na obecność ACC, natomiast brak niebieskich pikseli wyklucza inne typy raka, takie jak LCC, normalna tkanka czy SCC. Z kolei drugi rząd ukazuje odwrotny wzorec – brak czerwonych pikseli na obrazach SHAP dla ACC, tkanki normalnej i SCC oraz wyraźna obecność czerwonych pikseli pozwala jednoznacznie zidentyfikować obraz jako należący do klasy LCC. Ten wzorec powtarza się w trzecim i czwartym rzędzie, dostarczając jasnych dowodów na obecność lub brak określonych typów raka płuc.

2.7.2. GRAD-CAM

Grad-CAM [46, 47] (ang. *Gradient-weighted Class Activation Mapping*) to metoda interpretacji modeli głębokiego uczenia, szczególnie konwolucyjnych sieci neuronowych, która umożliwia wizualizację obszarów obrazu najbardziej istotnych dla podjęcia konkretnej decyzji klasyfikacyjnej. Technika ta bazuje na analizie gradientów funkcji celu względem aktywacji w wybranej warstwie konwolucyjnej, co pozwala na uzyskanie mapy aktywacji o wymiarach przestrzennych odpowiadających cechom ekstraktowanym przez sieć. Mechanizm działania Grad-CAM polega na obliczeniu wag dla poszczególnych filtrów warstwy konwolucyjnej, które są wyznaczane jako średnia wartość gradientów funkcji celu względem tych filtrów. Następnie wagi te są wykorzystywane do liniowego połączenia aktywacji filtrów, co skutkuje powstaniem mapy cieplnej, wskazującej na regiony obrazu, które miały największy wpływ na ostateczną predykcję modelu. W efekcie uzyskujemy przestrzenną reprezentację istotności cech, która może być nałożona na oryginalny obraz, ułatwiając interpretację wyników klasyfikacji.



Rys. 2.5: Wizualizacja działania metody Grad-CAM na przykładzie zdjęcia CT. Źródło: Ennab i in. [47].

Na Rysunku 2.5 widoczna jest mapa cieplna Grad-CAM nałożona na obraz CT (tomografia komputerowa), która pokazuje, które rejony płuca model uznał za najważniejsze przy podejmowaniu decyzji. Te rejony zostały oznaczone białymi kółkami z wartością aktywacji. Po prawej stronie znajduje się skala kolorów od niebieskiego, który wskazuje na niską aktywację, po kolor czerwony, wskazujący na wysoką aktywację. Czerwone obszary oznaczają fragmenty obrazu o największym znaczeniu dla modelu.

Rozdział 3

Protokół eksperymentalny i plany eksperymentów

W niniejszym rozdziale przedstawiono wykorzystany zbiór danych oraz szczegółowy protokół eksperymentalny, obejmujący opis procedur badawczych zastosowanych w ramach przeprowadzonych analiz.

3.1. Pytania badawcze


Wszystkie eksperymenty przeprowadzono, aby odpowiedzieć na cztery kluczowe pytania:

1. Które z analizowanych architektur wykazują najwyższą skuteczność w adaptacji do nowego zadania, poprzez wykorzystanie nabytej wcześniej wiedzy?
2. Który z analizowanych modeli cechuje się najwyższą zdolnością do prawidłowego rozpoznawania stopnia zaawansowania retinopatii cukrzycowej, uwzględniając jakość predykcji?
3. Jak dobrze analizowane modele radzą sobie z adaptacją i generalizacją, gdy liczba dostępnych próbek treningowych jest bardzo ograniczona?
4. Jakie cechy obrazu siatkówki wpływają na decyzje modelu?

3.2. Zbiór danych i przetwarzanie wstępne danych

Do realizacji badań wykorzystano zbiór danych pochodzący z konkursu „Diabetic Retinopathy Detection” dostępnego na platformie Kaggle [48]. Zbiór ten zawiera ponad 80 GB wysokorozdzielczych zdjęć siatkówki oka, zarejestrowanych przy użyciu różnych aparatów i modeli sprzętu okulistycznego, co wpływa na zróżnicowanie wizualne obrazów. Ze względu na ograniczenia sprzętowe zbiór ten zredukowano do około 11 tysięcy zdjęć. Dla każdego pacjenta dostępne są fotografie zarówno prawego, jak i lewego oka, oznaczone odpowiednio identyfikatorem pacjenta oraz sufiksem określającym stronę (np. „1_left.jpeg” odnosi się do lewego oka pacjenta o ID 1). Każde zdjęcie zostało ocenione przez specjalistę klinicznego pod kątem obecności i stopnia zaawansowania retinopatii cukrzycowej na skali od 0 do 4, gdzie:

- 0 oznacza brak retinopatii,
- 1 oznacza postać łagodną,
- 2 oznacza postać umiarkowaną,
- 3 oznacza postać ciężką,
- 4 oznacza proliferacyjną retinopatię cukrzycową.



Rys. 3.1: Przykładowe obrazy przedstawiające pięć stopni retinopatii cukrzycowej: No DR, Mild, Moderate, Severe, Proliferative.

Na Rysunku 3.1 przedstawiono kolejno klasy zaawansowania retinopatii cukrzycowej. Zbiór danych obrazowych wykorzystany w analizie charakteryzuje się istotną zmiennością orientacji przestrzennej obrazów siatkówki. Występują przypadki, w których obrazy są obrócone względem standardowej, anatomicznie poprawnej projekcji, zarówno w osi pionowej, poziomej, jak i w postaci rotacji o różne kąty. Tego rodzaju niejednorodność wynika najczęściej z nieprecyzyjnego pozycjonowania pacjenta względem aparatu obrazującego lub braku automatycznego wyrównania podczas wstępnego przetwarzania danych.

Identyfikacja właściwej orientacji anatomicznej opiera się na analizie rozpoznawalnych struktur morfologicznych charakterystycznych dla obrazów dna oka. Kluczowe znaczenie mają tutaj: relatywna lokalizacja plamki żółtej względem tarczy nerwu wzrokowego, obecność naczyń siatkówki o typowym układzie promienistym, a także inne pomocnicze wskaźniki wizualne, takie jak nieregularności krawędzi (np. wcięcia lub artefakty wynikające z niepełnego skanowania).

Ze względu na istotną nierównowagę klas w oryginalnym zbiorze danych, w którym przypadki oznaczone jako brak retinopatii (klasa 0) dominowały liczebnie (ponad 25 tysięcy przykładów), podczas gdy klasy 3 i 4 były reprezentowane przez mniej niż 1000 próbek każda, podjęto decyzję o zredukowaniu zbioru do 11 236 przykładów. Celem tej redukcji było częściowe wyrównanie rozkładu klas, który po przekształceniu przyjął następującą postać:

- Klasa 0 – 4000 obrazów
- Klasa 1 – 2300 obrazów
- Klasa 2 – 2415 obrazów
- Klasa 3 – 1390 obrazów
- Klasa 4 – 1131 obrazów

Pomimo zastosowanych zabiegów, zbiór nadal wykazuje cechy nierównomiernego rozkładu klas, co może prowadzić do uprzywilejowanego traktowania dominującej klasy przez model predykcyjny. W celu ograniczenia tego zjawiska zastosowano mechanizm ważenia klas w funkcji kosztu, co pozwala na penalizowanie błędów klasyfikacyjnych w klasach mniejszościowych, a tym samym wymusza większą uwagę modelu na przypadkach rzadziej reprezentowanych.

Ponadto, zbiór danych zawiera obrazy obarczone zakłóceniami w postaci szumów i artefaktów. Są to między innymi przypadki zdjęć niewyraźnych, nieostrych, prześwietlonych, niedoświetlonych, jak również z nadmiernym kontrastem lub nietypową kolorystyką. Zróżnicowanie jakości obrazów jest efektem niejednorodnych warunków ich pozyskiwania (różne modele kamer, protokoły, operatorzy, warunki oświetleniowe) i stanowi istotne wyzwanie w kontekście ekstrakcji cech istotnych dla klasyfikacji, zwiększając ryzyko obniżenia skuteczności działania modelu uczącego się. Jednocześnie, obecność tego typu zniekształceń odzwierciedla realne warunki kliniczne, co może przyczyniać się do lepszej generalizacji modelu w środowisku produkcyjnym, o ile zostaną podjęte odpowiednie środki zaradcze, np. augmentacja danych czy filtrowanie niskiej jakości próbek.

W celu zwiększenia ogólności modelu oraz redukcji ryzyka przeuczenia zastosowano zestaw transformacji augmentacyjnych na zbiorze treningowym. Przetwarzanie danych wejściowych realizowane było z wykorzystaniem następujących operacji:

- zmianę rozdzielczości obrazu do wymiarów 224×224 pikseli,
- losowe poziome odbicie obrazu (*RandomHorizontalFlip*),
- losową rotację w zakresie $\pm 10^\circ$ (*RandomRotation*),
- losowe kadrowanie z przeskalowaniem przy zachowaniu wymiarów wyjściowych (*RandomResizedCrop*, ze skalą w zakresie od 0,8 do 1,0),
- modyfikację parametrów jasności, kontrastu oraz nasycenia obrazu (*ColorJitter* z amplitudą 0,2 dla każdego z parametrów),
- konwersję obrazu do tensora (*ToTensor*),
- normalizację pikseli względem średnich wartości kanałów RGB: [0,485, 0,456, 0,406] oraz odchyłeń standardowych [0,229, 0,224, 0,225].

Z kolei dla zbiorów walidacyjnego oraz testowego ograniczono się jedynie do operacji standaryzujących: zmianę rozmiaru do 224×224 , konwersję do tensora oraz normalizację z wykorzystaniem tych samych parametrów co w przypadku zbioru treningowego.

3.3. Przebieg eksperymentów

W niniejszej pracy do analizy problemu klasyfikacji retinopatii cukrzycowej wykorzystano zestaw nowoczesnych modeli opartych na architekturze transformera, które charakteryzują się wysoką skutecznością w zadaniach wizji komputerowej oraz dużą zdolnością do uogólniania wiedzy. Wybrane modele reprezentują różne podejścia do przetwarzania obrazów i uczenia reprezentacji, co pozwala na ich kompleksowe porównanie pod kątem efektywności, odporności na zakłócenia oraz zdolności transferu wiedzy. Każdy z modeli został wybrany ze względu na swoje unikalne właściwości oraz przydatność w kontekście analizy danych obrazowych z zakresu okulistyki. Szczegółowy opis modeli zawarto w Rozdziale 2.4.

Eksperymenty badawcze oraz proces trenowania modeli zostały przeprowadzone przy użyciu lokalnej stacji roboczej wyposażonej w kartę graficzną NVIDIA GeForce GTX 1060 z 6 GB pamięci VRAM, sześciordzeniowy procesor Intel Core i5-12400F taktowany zegarem 2.50 GHz oraz 16 GB pamięci operacyjnej RAM. Wszystkie analizowane modele, z wyjątkiem architektury RETFound, były trenowane w całości na powyższej konfiguracji sprzętowej. Z uwagi na wysoką


złożoność obliczeniową oraz pamięciożerność modelu RETFound, wynikającą m.in. z jego złożonej architektury oraz specjalizacji w przetwarzaniu obrazów medycznych, jego testowanie zostało przeprowadzone przy wykorzystaniu zasobów obliczeniowych udostępnionych przez Katedrę Systemów i Sieci Komputerowych Politechniki Wrocławskiej. Pozwoliło to na włączenie tego zaawansowanego modelu do porównania eksperymentalnego bez konieczności ograniczania liczby epok lub rozmiaru danych.

Do treningu wykorzystano zbiór danych, który został podzielony na trzy części: treningową, walidacyjną oraz testową. Podział ten został wykonany w sposób równomierny, z zachowaniem proporcji poszczególnych klas w każdym z podzbiorów, aby zapewnić ich odpowiednie zbalansowanie. Dzięki temu każdy z zestawów - treningowy, walidacyjny i testowy – reprezentował podobny rozkład klas, co jest kluczowe dla rzetelnej nauki i oceny modeli. Wszystkie modele otrzymywały jako dane wejściowe obrazy przeskalowane do rozdzielczości 224×224 piksele. Proces trenowania prowadzony był przez 100 epok z wykorzystaniem optymalizatora ADAM, ustawionego na wartość współczynnika uczenia równą $5e-6$, przy jednoczesnym zastosowaniu harmonogramu uczenia typu StepLR, umożliwiającego dynamiczną regulację tempa uczenia w trakcie kolejnych epok.

W kontekście niniejszej pracy wykorzystany zbiór danych obejmuje około 11 tysięcy obrazów. Jego rozmiar, wraz z zastosowanymi technikami augmentacji oraz ważenia klas, pozwala na uznanie go za zbiór stosunkowo duży i zrównoważony. W związku z tym decyzja o rezygnacji z walidacji krzyżowej została podjęta ze względu na ograniczone zasoby obliczeniowe oraz znaczące wydłużenie czasu treningu, jakie niesie za sobą jej implementacja, przy jednoczesnym ograniczonym wzroście wartości informacyjnej uzyskanych wyników.

Nie przeprowadzono również testów statystycznych porównujących wyniki modeli, co wynika z braku zastosowania walidacji krzyżowej, co zostało uzasadnione wyżej. Testy statystyczne, takie jak testy istotności czy porównania par modeli na wielu podzbiorach danych, wymagają powtarzalnych wyników uzyskanych na różnych losowych podziałach zbioru, co umożliwia walidacja krzyżowa lub inne techniki wielokrotnego dzielenia danych. Bez tych powtórzeń uzyskane wyniki traktowane są jako pojedyncze obserwacje, co uniemożliwia rzetelną ocenę ich statystycznej istotności.

Poniżej (Rys. 3.2) zaprezentowano wykres ilustrujący zmiany wartości funkcji straty oraz metryki dokładności zbalansowanej (ang. *balanced accuracy score*) w trakcie procesu treningowego modelu ResNet50, w zależności od liczby przeprowadzonych epok. Obserwuje się, że wraz ze wzrostem liczby epok funkcja straty systematycznie maleje, co świadczy o efektywnym dopasowywaniu modelu do danych treningowych, natomiast metryka dokładności wykazuje tendencję wzrostową, potwierdzając poprawę jakości predykcji modelu. Dla pozostałych modeli wykresy są niemal identyczne, dlatego nie zostały tutaj zamieszczone.



Rys. 3.2: Wykres zależności wartości funkcji strat oraz zrównoważonej dokładności od liczby epok dla modelu ResNet50

3.4. Scenariusze eksperymentów

3.4.1. Eksperyment 1 - Porównanie modeli pod kątem ich zdolności do transferu wiedzy

W ramach niniejszego eksperymentu dokonano oceny zdolności wybranych modeli do transferu wiedzy, wykorzystując do tego celu metryki omówione szczegółowo w rozdziale 2.6.3. Głównym celem badania była identyfikacja architektur, które wykazują najwyższą skuteczność w adaptacji do nowego zadania, jakim jest klasyfikacja retinopatii cukrzycowej na podstawie obrazów dna oka, poprzez efektywne wykorzystanie uprzednio nabytej wiedzy. Eksperyment miał na celu odpowiedź na pytanie, który z analizowanych modeli cechuje się największym potencjałem w kontekście transfer learningu oraz czy zastosowane metryki są wystarczająco stabilne i miarodajne, by na ich podstawie dokonać świadomego wyboru modelu do dalszych analiz.

Oprócz porównania wartości wybranych metryk pomiędzy modelami, zestawiono także modele wstępnie wytrenowane z ich niepretrenowanymi odpowiednikami. Z wybranych modeli pozyskano osadzenia, które następnie posłużyły jako dane wejściowe do regresji logistycznej. W tym porównaniu punktem odniesienia była regresja logistyczna uczona na losowych wagach, bez wcześniejszego transferu wiedzy. Analiza ta miała na celu empiryczne potwierdzenie, czy wcześniejsze pretrenowanie modeli rzeczywiście przyczynia się do lepszej reprezentacji danych i poprawy skuteczności uczenia w kontekście nowego zadania.

3.4.2. Eksperyment 2 - Porównanie modeli pod kątem klasyfikacji

Celem przeprowadzonego eksperymentu była wszechstronna i systematyczna analiza efektywności wybranych architektur głębokich sieci neuronowych w zadaniu klasyfikacji stopnia zaawansowania retinopatii cukrzycowej na podstawie obrazów dna oka. Wszystkie modele zostały wytrenowane na jednakowym, uprzednio przygotowanym i zbalansowanym zbiorze danych, co pozwoliło na zachowanie spójnych warunków eksperymentalnych oraz rzetelne porównanie ich skuteczności.

Ocena wydajności poszczególnych modeli została przeprowadzona w oparciu o zestaw metryk ewaluacyjnych, które szczegółowo omówiono w rozdziale 2.6.2. Zastosowanie wielu różnych miar umożliwiło wielowymiarową ocenę zdolności klasyfikacyjnych badanych algorytmów. Podejście to pozwoliło nie tylko na ocenę trafności predykcji, ale również na wnikliwą analizę stabilności działania modeli.

Eksperyment miał na celu odpowiedź na zasadnicze pytanie badawcze: która z analizowanych architektur wykazuje najwyższą skuteczność w kontekście klasyfikacji retinopatii cukrzycowej, zarówno pod względem trafności prognoz, jak i ogólnej zdolności do uogólniania nabytej wiedzy.

3.4.3. Eksperyment 3 - Porównanie modeli pod kątem klasyfikacji w przypadku ograniczonych danych

W tym eksperymencie przeprowadzono analizę skuteczności wybranych modeli w warunkach ograniczonej liczby danych treningowych. Tego rodzaju scenariusz odzwierciedla realne wyzwania, jakie często występują w zastosowaniach medycznych, gdzie pozyskanie dużych, wysokiej jakości zbiorów danych etykietowanych przez ekspertów bywa kosztowne, czasochłonne lub wręcz niemożliwe.

Aby ilościowo ocenić zdolność modeli do generalizacji przy niewielkiej liczbie przykładów uczących, wykorzystano metrykę *few-shot accuracy* (opisana w Rozdziale 2.6.3). Jest to dokładność klasyfikacji mierzona po wytrenowaniu modelu (lub jego części) na silnie ograniczonym podziorze danych treningowych - w tym przypadku były to próbki z [2, 10, 20, 40, 100, 200] przykładami na klasę. Metryka ta pozwala oszacować, jak dobrze dany model radzi sobie z adaptacją do nowego zadania przy minimalnej ilości informacji.

Celem eksperymentu było określenie, który z analizowanych modeli wykazuje najwyższą odporność na ograniczenia związane z liczbą dostępnych próbek oraz najlepiej generalizuje wiedzę w warunkach skrajnego niedoboru danych.

3.4.4. Eksperyment 4 - Wyjaśnialność

Celem niniejszego eksperymentu była analiza procesu decyzyjnego modelu w kontekście zadania klasyfikacji stopnia zaawansowania retinopatii cukrzycowej, ze szczególnym uwzględnieniem identyfikacji kluczowych obszarów obrazu siatkówki, które miały największy wpływ na wygenerowaną predykcję. W tym celu zastosowano technikę Grad-CAM, której szczegółowy opis zawarto w rozdziale 2.7.2.

Ocena poprawności i przydatności wygenerowanych map uwagi została przeprowadzona manualnie, na podstawie dostępnej literatury dotyczącej retinopatii cukrzycowej oraz charakterystycznych zmian widocznych na obrazach dna oka. Analiza ta pozwoliła zweryfikować, czy model kieruje swoją uwagę na obszary istotne z medycznego punktu widzenia, co ma kluczowe znaczenie w kontekście interpretowalności i potencjalnego zastosowania modelu w praktyce klinicznej.

Eksperyment odpowiada na pytanie, czy analizowane modele klasyfikujące stopień zaawansowania retinopatii cukrzycowej podejmują decyzje w oparciu o obszary obrazu istotne z medycznego punktu widzenia, a także czy ich predykcje są możliwe do interpretacji przez człowieka.

Rozdział 4

Eksperymenty i wyniki

W niniejszym rozdziale zaprezentowano wyniki przeprowadzonych eksperymentów wraz z ich szczegółową analizą.

4.1. Ewaluacja wyników pod kątem zdolności do transferu wiedzy

Tabela zawiera zestawienie wyników uzyskanych przez poszczególne modele w kontekście oceny jakości reprezentacji oraz efektywności transferu wiedzy. Dodatkowo uwzględniono wartości zbalansowanej dokładności oraz wskaźnika ROC AUC, uzyskane w ramach odrębnego eksperymentu klasyfikacyjnego - nie są to metryki transferu, natomiast pełnią funkcje odniesienia.

Tab. 4.1: Porównanie metryk transferu dla różnych modeli

Metryka	RETFound	ResNet50	Swin Transformer	MedVit
TransRate score	18.44	18.43	57.10	85.96
H-score	0.07	0.12	0.11	0.08
LogDet Divergence	2.38	5.57	8.56	9.47
logME	-0.34	-0.14	-0.15	-0.20
NCE	-1.22	-0.07	-0.39	-0.44
Balanced Accuracy	0.71	0.63	0.67	0.61
ROC AUC	0.92	0.87	0.93	0.90

W analizie metryk oceniających jakość reprezentacji cech, modele RETFound oraz ResNet50 uzyskały relatywnie niskie wartości **TransRate** (18.44), podczas gdy Swin Transformer i MedVit osiągnęły znacznie wyższe wyniki - z najlepszym rezultatem odnotowanym dla MedVit (85.96). Warto jednak podkreślić, że metryka TransRate została pierwotnie opracowana z myślą o danych naturalnych, takich jak obrazy z zestawu ImageNet, a nie danych medycznych, w szczególności obrazach siatkówki. RETFound, jako model bazowy wyspecjalizowany w analizie okulistycznych danych obrazowych, generuje reprezentacje silnie ukierunkowane na istotne klinicznie cechy, które mogą nie przekładać się bezpośrednio na wysoką ocenę w ramach tej metryki. Z kolei wysokie wyniki osiągnięte przez Swin Transformera oraz MedVit mogą świadczyć o większej ogólności i uniwersalności ich reprezentacji. Należy jednak zauważyć, że taka uniwersalność może odbywać się kosztem uchwycenia subtelnych, dziedzicznie specyficznych informacji, które są kluczowe w zastosowaniach medycznych.

Analiza metryki **H-score** pokazuje, że jej wartości pozostają stosunkowo niskie we wszystkich badanych przypadkach (najwyższym wynikiem jest 0.12), co może wskazywać na ograniczoną separowalność klas w przestrzeni osadzeń. W kontekście danych medycznych nie musi to być jednak negatywna cecha - niska wartość H-score może odzwierciedlać obecność subtelnych zmian patologicznych, trudnych do jednoznacznego rozdzielenia, lecz istotnych z perspektywy diagnostycznej. Modele o charakterze ogólnego przeznaczenia, takie jak ResNet50 czy Swin Transformer, mogą bardziej koncentrować się na cechach wizualnych takich jak tekstura czy kolor, co przekłada się na wyższe H-score, ale może jednocześnie ograniczać ich przydatność kliniczną.

W kontekście metryki **LogDet**, najniższy jej poziom osiąga model RETFound (2.38), co sugeruje, że generowane przez niego reprezentacje są zwarte i strukturalnie jednorodne. Taka właściwość jest szczególnie cenna w analizie obrazów siatkówki, gdzie różnice między klasami mogą być bardzo subtelne. Najlepszy wynik w tym zakresie uzyskał MedVit (9.47), co można tłumaczyć jego trenowaniem na szerszym zakresie danych medycznych, obejmującym obrazy o innej specyfice niż okulistyczna, podobnie jak miało to miejsce w przypadku modeli ResNet i Swin Transformer.

Analizując wartości metryk **logME** oraz **NCE**, można zauważyć, że najniższe wyniki uzyskał model RETFound (odpowiednio: -0.34 oraz -1.22), co sugeruje jego relatywnie niższą użyteczność w kontekście transferu reprezentacji. Najwyższe wartości, wskazujące na potencjalnie lepszą transferowalność, odnotował natomiast ResNet50 (logME: -0.14; NCE: -0.07). Model Swin Transformer osiągnął zbliżony rezultat w logME (-0.15), jednak w przypadku NCE (-0.39) jego wynik wyraźnie odbiega od rezultatu uzyskanego przez ResNet50. Podobna tendencja widoczna jest dla MedVit (logME: -0.20; NCE: -0.44). Warto podkreślić, że zarówno logME, jak i NCE przyjmują wartości ujemne, co nie jest wynikiem błędu obliczeniowego, lecz bezpośrednią konsekwencją ich konstrukcji matematycznej. W przypadku logME, ujemne wartości wynikają z faktu, iż metryka ta operuje na logarytmie dowodu marginalnego, który dla większości realistycznych danych przyjmuje wartości poniżej jedności. Analogicznie, NCE z definicji zawiera negatywną entropię warunkową, która, jako miara niepewności, jest zawsze nieujemna, co powoduje, że jej negacja przybiera wartości ujemne.

Na podstawie uzyskanych wyników można zauważyć, że poszczególne metryki transferowalności prowadzą do odmiennych wniosków dotyczących efektywności modeli. W zależności od wybranej miary, inny model może zostać uznany za najbardziej obiecujący. Pomimo swojej relatywnie prostej architektury, ResNet50 osiąga najlepsze rezultaty wśród porównywanych modeli, co może być zaskakujące w kontekście RETFounda, czyli modelu o znacznie bardziej złożonej architekturze, pretrenowanego dodatkowo na ponad milionie obrazów siatkówki. Teoretycznie należałoby się spodziewać, że taki model wykazuje większą zdolność do transferu wiedzy. Jak wskazano w pracy autortwa Andreai Agostinelli i in. [49], metryki służące do oceny potencjału transferowego modeli są niestabilne i niewystarczająco wiarygodne, szczególnie w kontekście klasyfikacji obrazów medycznych. Autorzy przeprowadzili obszerne eksperymenty na wielu zbiorach danych i wykazali, że różne metryki (np. logME, NCE, H-score) często prowadzą do sprzecznych ocen tego samego modelu, co znacząco utrudnia wybór najlepszego rozwiązania. W konsekwencji, metryki te nie powinny być stosowane jako jedyne kryterium wyboru modelu w zadaniach transferu uczenia, zwłaszcza w zastosowaniach medycznych, gdzie dane charakteryzują się dużą złożonością i specyfiką dziedzinową. Obserwacje te znajdują potwierdzenie w pracy autorstwa Levy Chaves [50], w której autorzy dochodzą do wniosku, że nie należy jeszcze polegać na metrykach transferowalności przy wyborze modelu źródłowego do analizy obrazów medycznych. Również w niniejszym badaniu zauważono, że zastosowane metryki wykazują niespójność, a ich wartości niejednokrotnie nie korelują z rzeczywistą skutecznością klasyfikacji. W związku z tym należy traktować je wyłącznie jako narzędzia

wspomagające analizę potencjału reprezentacji, które mogą dostarczać ogólnej informacji, ale nie powinny stanowić decydującego kryterium wyboru modelu w zastosowaniach praktycznych.

Ponadto porównywanie architektur badanych modeli jest utrudnione ze względu na istotne różnice zarówno w ich budowie, jak i w zbiorach danych wykorzystanych do pretrenowania. W celu częściowego zniwelowania tego problemu wprowadzono metrykę Transfer Gain, umożliwiającą ocenę wpływu wstępnie wyuczonych reprezentacji na skuteczność klasyfikatora regresji logistycznej. Należy jednak zaznaczyć, że również to podejście ma swoje ograniczenia. Na przykład, w przypadku złożonych modeli takich jak RETFound, metryka ta może nie być w stanie w pełni uchwycić potencjału modelu ani odpowiednio odzwierciedlić jego skuteczności, ze względu na uproszczony charakter zastosowanego klasyfikatora oraz ograniczoną zdolność jego adaptacji do złożonych reprezentacji cech.


Tab. 4.2: Porównanie uczenia od zera z transferem wiedzy z pretrenowanych modeli

Metryka	RETFound	ResNet50	Swin Transformer	MedVit
Transfer Gain	0.31 (152%)	0.66 (334%)	0.59 (286%)	0.58 (290%)
ACC_pretrained	0.52	0.85	0.81	0.78
ACC_scratch	0.21	0.20	0.21	0.20


W przypadku metryki **Transfer Gain**, model ResNet50, charakteryzujący się stosunkowo prostą architekturą, wykazuje najwyższy wynik, co sugeruje, że generowane przez niego osadzenia są zarówno informatywne, jak i dobrze przystosowane do liniowej separacji przez regresję logistyczną. Modele Swin Transformer oraz MedViT prezentują umiarkowany wzrost Transfer Gain, co wskazuje na skuteczne, aczkolwiek bardziej złożone reprezentacje cech, które nadal mogą być efektywnie wykorzystywane przez klasyfikator liniowy, choć z pewnymi ograniczeniami. Natomiast model RETFound, mimo że jest pretrenowany na danych specyficznych dla badanego problemu, wykazuje najniższy przyrost Transfer Gain. Skomplikowana architektura RETFound może prowadzić do generowania osadzeń o bardziej nieliniowej i złożonej strukturze, co utrudnia ich efektywną klasyfikację przez regresję logistyczną, ograniczając tym samym zdolność do transferu wiedzy mierzoną tą metryką. W rezultacie, złożoność modelu może w tym kontekście stanowić czynnik obniżający mierzalny przyrost Transfer Gain, mimo potencjalnie wysokiej jakości reprezentacji.

Z badań dotyczących użyteczności transferu wiedzy, można jednoznacznie stwierdzić, że wcześniejsze pretrenowanie modelu oraz wykorzystanie wbudowanych osadzeń znacząco poprawia wyniki osiągane na nowym zadaniu. Dlatego stosowanie podejścia transfer learning jest szczególnie zalecane w sytuacjach, gdy kluczowym jest uzyskanie wysokiej skuteczności na nowym zadaniu przy ograniczonych zasobach sprzętowych lub czasie treningu.


Oprócz zaproponowanych metryk oceniających zdolność modeli do transferu wiedzy, przeprowadzono również analizę rozkładu reprezentacji wewnętrznych przy użyciu wykresów PCA oraz t-SNE, osobno dla każdego z rozważanych modeli. Poniżej przedstawiono rezultaty.




Rys. 4.1: Wykres PCA = 2 dla RETFound




Rys. 4.2: Wykres t-SNE dla RETFound




Rys. 4.3: Wykres PCA = 2 dla MedVit




Rys. 4.4: Wykres t-SNE dla MedVit




Rys. 4.5: Wykres PCA = 2 dla SwinTransformer



Rys. 4.6: Wykres t-SNE dla SwinTransformer



Rys. 4.7: Wykres PCA = 2 dla ResNet50



Rys. 4.8: Wykres t-SNE dla ResNet50

Na przedstawionych wykresach zaprezentowano wizualizację osadzonych reprezentacji danych. Dla każdego modelu zastosowano dwie metody redukcji wymiarowości - PCA oraz t-SNE, odpowiednio zilustrowane na Rysunkach 4.1, 4.3, 4.5 i 4.7 (PCA) oraz 4.2, 4.4, 4.6 i 4.8 (t-SNE). Oś X oraz Y odpowiadają dwóm najistotniejszym składowym w przypadku PCA, natomiast w t-SNE dwóm wybranym wymiarom odpowiadającym lokalnym strukturalnym danych. Kolory reprezentują różne klasy danych, gdzie każda wartość odpowiada odrębnej etykietce klasowej. Analiza wizualizacji PCA dla modelu RETFound wskazuje na umiarkowane nakładanie się klas, z widocznymi jednak pewnymi skupiskami, co jest zgodne z charakterystyką PCA jako metody zachowującej głównie globalną strukturę danych, kosztem słabszego odwzorowania lokalnych zależności. Różnorodność w rozciągnięciu klas sugeruje zróżnicowanie rozkładu cech w przestrzeni osadzeń. Z kolei t-SNE dla RETFound wyraźniej eksponuje rozdzielczość klas poprzez lepsze zachowanie lokalnej topologii, co przekłada się na bardziej zwarte i wyraźne klastry, umożliwiające łatwiejszą interpretację grup podobnych próbek.

W przypadku modelu MedVit PCA ukazuje bardziej rozproszone osadzenia z mniej wyraźnymi skupiskami, co może świadczyć o bardziej złożonym lub nieliniowym charakterze cech, trudnym do uchwycenia przez metody liniowe. t-SNE z kolei poprawia rozdzielczość lokalnych struktur, generując lepiej wyodrębnione klastry, choć nadal mniej zwarte i bardziej rozproszone w porównaniu do RETFound.

Podobną charakterystykę wizualizacji osadzeń zaobserwowano dla modeli Swin Transformer oraz ResNet50, które wykazują zachowanie zbliżone do MedVit. W przypadku analizy PCA zauważalne jest wyraźne, choć stosunkowo zwarte skupisko danych, z nieco lepiej wyodrębnioną klasą 0, co sugeruje umiarkowaną separację tej kategorii od pozostałych. Niemniej jednak, inne klasy pozostają w dużym stopniu nakładające się, co wskazuje na ograniczoną zdolność PCA do pełnego rozdzielania przestrzeni cech tych modeli. Analiza t-SNE ujawnia znaczne rozproszenie osadzeń, przy czym widoczne są nieliczne, słabo wyodrębnione klastry klasy 0. Rozproszenie oraz luźne klastry wskazują na bardziej złożoną, nieliniową strukturę reprezentacji, która nie daje się łatwo sprowadzić do wyraźnych grup w przestrzeni dwuwymiarowej. Takie zachowanie jest typowe dla t-SNE w przypadku danych o dużej złożoności i może świadczyć o trudności w jednoznacznym rozgraniczeniu klas na podstawie wygenerowanych embeddingów.

Analiza wizualizacji osadzeń danych wskazuje, że metoda t-SNE przewyższa PCA pod względem zdolności do rozdzielania klas, co wynika z jej lepszego zachowania lokalnych relacji między próbkami. W przypadku modelu RETFound zaobserwowano wyraźniejszą kompaktowość oraz lepszą separację klastrów, co sugeruje, że reprezentacje tego modelu są bardziej dopasowane do zadania klasyfikacji i charakteryzują się wyższą rozróżnialnością cech w porównaniu do

MedVit, którego embeddingi cechują się większym rozproszeniem i bardziej złożoną, nieliniową strukturą. Analogicznie, wizualizacje dla Swin Transformer oraz ResNet50 wskazują na umiarkowaną separowalność klas, ze szczególnym uwypukleniem klasy 0, jednakże ogólna struktura cech pozostaje rozproszona i nieliniowa. Takie rozproszenie może ograniczać efektywność klasyfikacji opierającej się wyłącznie na tych reprezentacjach, co podkreśla potrzebę stosowania bardziej zaawansowanych metod analizy cech lub klasyfikatorów zdolnych do radzenia sobie z nieliniowością danych.

4.2. Ewaluacja wyników pod kątem skuteczności klasyfikacji wieloklasowej

Ze względu na niejednoznaczność wyników ewaluacji zdolności modeli do transferu wiedzy, zdecydowano się na przetestowanie skuteczności klasyfikacji wieloklasowej wszystkich modeli uwzględnionych w pracy. Wyniki tego porównania zostały przedstawione w poniższej tabeli.

Tab. 4.3: Porównanie wyników modeli na zbiorze testowym

Metryka	RETFound	MedVit	Swin Transformer	ResNet50
Balanced Accuracy	0.709	0.612	0.666	0.626
Precision	0.712	0.804	0.674	0.688
Recall	0.709	0.790	0.666	0.698
F1 Score	0.710	0.787	0.664	0.648
ROC AUC	0.917	0.900	0.934	0.874
QWK	0.593	0.865	0.710	0.866

Analiza przedstawionych wyników modeli RETFound, MedVit, Swin Transformer oraz ResNet50 na zbiorze testowym ukazuje wyraźne zróżnicowanie efektywności poszczególnych architektur w kontekście różnych metryk ewaluacyjnych.

Model **RETFound** osiągnął bardzo solidne wyniki, szczególnie w metrykach takich jak Balanced Accuracy (0.709), Precision (0.712), Recall (0.709) oraz F1 Score (0.710). To pokazuje, że model ten dobrze balansuje między dokładnością klasyfikacji a wykrywaniem przypadków retinopatii, co jest kluczowe w medycznym zastosowaniu, gdzie ważne jest minimalizowanie fałszywych alarmów. Wysoki wynik ROC AUC (0.917) świadczy o znakomitej zdolności modelu do rozróżniania między różnymi klasami na różnych progach decyzyjnych, co oznacza, że RETFound jest skuteczny i elastyczny w działaniu. Jednak współczynnik kwadratowego kappa (QWK) na poziomie 0.5929 wskazuje na umiarkowaną zgodność klasyfikacji z rzeczywistymi etykietami. Co ważniejsze, sugeruje to, że model popełnia błędy o większej wadze, na przykład myli klasę 1 z klasą 4, co w kontekście medycznym jest znaczącym i niepożądanym błędem.

Model **MedVit** osiąga wysokie wyniki w metrykach takich jak Precision (0.804), Recall (0.790) oraz F1 Score (0.787), co świadczy o jego skuteczności w prawidłowym wykrywaniu pozytywnych przypadków i ogólnej równowadze między precyzją a czułością. Ponadto, wysoki QWK na poziomie 0.865 wskazuje na bardzo dobrą zgodność klasyfikacji modelu z rzeczywistymi etykietami, minimalizując błędy o dużej wadze. Wynik ROC AUC (0.900) również potwierdza solidną zdolność rozróżniania klas w różnych progach decyzyjnych.

Model **Swin Transformer** wyróżnia się najwyższym wynikiem ROC AUC (0.934), co wskazuje na jego doskonałą zdolność do rozróżniania klas przy różnych progach decyzyjnych. Jednak w metrykach takich jak Balanced Accuracy (0.666), Recall (0.666) i F1 Score (0.664) wypada nieco słabiej niż RETFound i MedVit, co sugeruje, że mimo dobrej separacji klas, model może mieć

problem z równomiernym wykrywaniem pozytywnych przypadków. Wartość QWK na poziomie 0.710 jest umiarkowanie wysoka, wskazując na poprawną zgodność klasyfikacji z rzeczywistymi etykietami, choć nie tak dobrą jak w przypadku MedViT i ResNet50.

ResNet50 osiąga umiarkowane wyniki w większości metryk, z Balanced Accuracy na poziomie 0.626 oraz F1 Score wynoszącym 0.648, co wskazuje na przeciętną zdolność do poprawnej klasyfikacji i wykrywania pozytywnych przypadków. Warto jednak zwrócić uwagę na wysoki QWK (0.866), który sugeruje dobrą zgodność klasyfikacji z rzeczywistymi etykietami, zwłaszcza uwzględniając różnice wag błędów klasyfikacji. ROC AUC na poziomie 0.874 świadczy o solidnej zdolności modelu do rozróżniania klas, choć jest niższy niż u Swin Transformera czy RETFound.

Po przeprowadzeniu ogólnej analizy uśrednionych wyników, przeprowadzono również szczegółową ewaluację wybranych metryk w podziale na poszczególne klasy. Uzyskane wyniki przedstawiono w tabelach poniżej.

Tab. 4.4: Wyniki metryk dla poszczególnych klas w modelu RETFound

Klasa	Balanced Accuracy	Precision	Recall (TPR)	Specificity (TNR)
0 – No DR	0.812	0.850	0.780	0.843
1 – Mild DR	0.668	0.620	0.590	0.746
2 – Moderate DR	0.681	0.700	0.660	0.702
3 – Severe DR	0.659	0.615	0.610	0.708
4 – Proliferative DR	0.722	0.685	0.690	0.754

Tab. 4.5: Wyniki metryk dla poszczególnych klas w modelu MedViT

Klasa	Balanced Accuracy	Precision	Recall (TPR)	Specificity (TNR)
0 – No DR	0.790	0.880	0.860	0.720
1 – Mild DR	0.605	0.770	0.720	0.490
2 – Moderate DR	0.580	0.760	0.710	0.450
3 – Severe DR	0.547	0.690	0.680	0.413
4 – Proliferative DR	0.640	0.720	0.790	0.490

Tab. 4.6: Wyniki metryk dla poszczególnych klas w modelu Swin Transformer

Klasa	Balanced Accuracy	Precision	Recall (TPR)	Specificity (TNR)
0 – No DR	0.740	0.780	0.750	0.730
1 – Mild DR	0.645	0.670	0.620	0.670
2 – Moderate DR	0.610	0.640	0.600	0.620
3 – Severe DR	0.630	0.620	0.610	0.650
4 – Proliferative DR	0.644	0.660	0.680	0.609

Tab. 4.7: Wyniki metryk dla poszczególnych klas w modelu ResNet50

Klasa	Balanced Accuracy	Precision	Recall (TPR)	Specificity (TNR)
0 – No DR	0.680	0.760	0.740	0.620
1 – Mild DR	0.590	0.640	0.670	0.510
2 – Moderate DR	0.610	0.630	0.600	0.620
3 – Severe DR	0.598	0.650	0.710	0.485
4 – Proliferative DR	0.652	0.650	0.770	0.535

W przypadku każdego z modeli zauważalna jest przewaga w rozpoznawaniu klasy 0, czyli braku retinopatii. W przypadku modelu **RETFound**, cechuje się on najwyższą skutecznością w rozpoznawaniu klasy 0, gdzie zarówno Balanced Accuracy (0.812), Precision (0.850), Recall (0.780), jak i Specificity (0.843) osiągają najlepsze wartości. Świadczy to o wysokiej zdolności modelu do prawidłowego klasyfikowania przypadków zdrowych. Dla pozostałych klas chorobowych (1–4) model uzyskuje umiarkowane wyniki, z Balanced Accuracy oscylującą w granicach 0.66–0.72, co wskazuje na umiarkowaną skuteczność w rozróżnianiu stopni retinopatii. Precision oraz Recall dla tych klas utrzymują się na poziomie około 0.60–0.70, co oznacza, że model jest w stanie wykrywać przypadki patologiczne z umiarkowaną dokładnością i czułością.

Najniższe wyniki dotyczą klasy 1 i klasy 3, co może wskazywać na trudności modelu w precyzyjnym rozróżnianiu tych stadiów retinopatii, co jest często spotykanym problemem ze względu na podobieństwo cech między stopniami choroby.

Z kolei dla klasy 4 model wykazuje nieco lepsze wyniki, szczególnie w Recall (0.690) oraz Balanced Accuracy (0.722), co może sugerować, że zaawansowane stadium retinopatii jest przez model relatywnie dobrze wykrywane.

Analiza dla modelu **MedViT** wskazuje, że najwyższą skuteczność osiąga on w klasyfikacji klasy 0, gdzie Balanced Accuracy wynosi 0.790, Precision 0.880, a Recall 0.860. Wysokie wartości tych wskaźników świadczą o bardzo dobrej zdolności modelu do wykrywania zdrowych próbek oraz ograniczaniu fałszywych alarmów.

Dla klas 1–4 model wykazuje obniżoną efektywność, szczególnie w przypadku klas 1–3, gdzie Balanced Accuracy spada poniżej 0.61, a Specificity osiąga niskie wartości (około 0.41–0.49). To sugeruje trudności w rozróżnianiu tych stadiów retinopatii oraz w precyzyjnym eliminowaniu fałszywych negatywów.

Klasa 4 charakteryzuje się relatywnie wyższym Balanced Accuracy (0.640) i najwyższym Recall spośród klas chorobowych (0.790), co wskazuje na skuteczność modelu w wykrywaniu zaawansowanego stadium retinopatii, choć Precision jest tu nieco niższe (0.720), co może oznaczać większą liczbę fałszywych pozytywów.

Model **Swin Transformer** osiąga najlepsze wyniki dla klasy 0, gdzie Balanced Accuracy wynosi 0.740, Precision 0.780, Recall 0.750 oraz Specificity 0.730. Te wartości świadczą o solidnej zdolności modelu do poprawnego rozpoznawania zdrowych próbek oraz efektywnym ograniczaniu błędów fałszywie pozytywnych i fałszywie negatywnych.

Dla klas chorobowych (1–4) model prezentuje umiarkowaną skuteczność, z Balanced Accuracy w zakresie 0.610–0.645. Precision i Recall są na podobnym poziomie, oscylując w okolicach 0.60–0.68, co wskazuje na umiarkowaną precyzję i czułość w wykrywaniu poszczególnych stopni retinopatii.

Najniższą wartość Balanced Accuracy model odnotowuje dla klasy 2 - 0.610, co może sugerować większe trudności w rozróżnianiu tego stadium. Jednocześnie Specificity dla wszystkich klas chorobowych utrzymuje się na umiarkowanym poziomie (około 0.61–0.67), co oznacza, że model stosunkowo dobrze ogranicza fałszywe alarmy.

Klasa 4 cechuje się nieco wyższym Recall (0.680), co oznacza, że model lepiej wykrywa zaawansowane stadium retinopatii, choć Precision (0.660) wskazuje na umiarkowany poziom fałszywych pozytywnych.

Analiza wyników metryk modelu **ResNet50** wskazuje, że najlepszą skuteczność model osiąga dla klasy 0, z Balanced Accuracy na poziomie 0.680, Precision 0.760 oraz Recall 0.740. Jednak Specificity jest stosunkowo niższe (0.620), co sugeruje umiarkowaną zdolność do eliminacji fałszywych pozytywnych.

Dla klas chorobowych model cechuje się umiarkowaną skutecznością. Balanced Accuracy oscyluje między 0.590 (klasa 1) a 0.652 (klasa 4). Precision oraz Recall utrzymują się w przedziale 0.630–0.770, co wskazuje, że model lepiej wykrywa przypadki zaawansowanych stadiów retinopatii (klasa 4) z wysokim Recall (0.770), ale precyzja pozostaje na umiarkowanym poziomie (0.650).

Najniższe wartości Specificity odnotowano dla klas 1 i 3 - odpowiednio 0.510 oraz 0.485, co wskazuje na podwyższoną liczbę fałszywych pozytywnych w tych klasach.

Analiza wyników różnych modeli pokazuje, że nie istnieje jedno uniwersalne rozwiązanie idealne pod każdą metrykę. Każda architektura wyróżnia się w innych aspektach - niektóre lepiej balansują precyzję i czułość, inne świetnie rozpoznają klasy, ale mogą mieć problem z wagą błędów klasyfikacyjnych. To podkreśla, jak istotne jest dopasowanie modelu do konkretnego zadania i oczekiwań, np. czy ważniejsza jest ogólna skuteczność, czy może minimalizacja ciężkich błędów. Wybór modelu to więc nie tylko kwestia "najlepszych wyników", ale też zrozumienia kontekstu zastosowania i świadomego kompromisu między wydajnością a zasobami.

W praktyce wybór modelu powinien uwzględniać nie tylko wyniki metryk klasyfikacyjnych, ale również aspekty takie jak złożoność obliczeniowa, stabilność działania oraz zgodność predykcji z oczekiwaniami klinicznymi, co jest szczególnie istotne w kontekście wymagań dotyczących interpretowalności i bezpieczeństwa w zastosowaniach medycznych. Przykładowo, model RETFound, mimo że oferuje wysoką skuteczność, charakteryzuje się dużymi wymaganiami sprzętowymi, co może stanowić barierę w mniej zasobnych środowiskach. W takich przypadkach warto rozważyć alternatywy, jak MedViT, który przy niższej złożoności obliczeniowej nadal osiąga konkurencyjne wyniki, stanowiąc tym samym praktyczne i efektywne narzędzie w realnych zastosowaniach.

4.3. Analiza zachowania modeli uczenia maszynowego w warunkach ograniczonej dostępności danych

W celu analizy zachowania modeli w warunkach ograniczonej liczby próbek treningowych przeprowadzono test few-shot accuracy, umożliwiający ocenę wydajności poszczególnych architektur w scenariuszach niskiej dostępności danych. Poniżej przedstawiono uzyskane wyniki dla każdego z badanych modeli.

RETFound, mimo swojej domenowej specjalizacji, uzyskuje niższe wartości dokładności w porównaniu do modeli ogólnego przeznaczenia w niemal wszystkich konfiguracjach liczby próbek. Najniższa dokładność (0.276) została osiągnięta przy 10 próbkach treningowych, natomiast przy 1000 próbkach model osiąga 0.513. Ta trajektoria wzrostu, choć systematyczna, jest wyraźnie bardziej płaska w porównaniu do pozostałych modeli. Wynik ten może wskazywać, że reprezentacje generowane przez RETFound są wysoko wyspecjalizowane i wymagają bardziej złożonych mechanizmów adaptacyjnych lub większych zbiorów danych do pełnego wykorzystania ich potencjału.

Swin Transformer, MedViT oraz ResNet50 wykazują podobną efektywność klasyfikacyjną w warunkach silnie ograniczonej liczby próbek uczących. W miarę wzrostu liczebności zbioru


Tab. 4.8: Dokładność klasyfikacji w zależności od liczby próbek treningowych

Liczba próbek	RETFound	Swin Transformer	MedViT	ResNet50
10	0.276	0.266	0.271	0.306
50	0.331	0.461	0.435	0.450
100	0.370	0.515	0.489	0.536
200	0.414	0.589	0.564	0.575
500	0.444	0.667	0.632	0.667
1000	0.513	0.711	0.689	0.703


treningowego obserwowany jest istotny wzrost jakości klasyfikacji, szczególnie w przypadku modeli ResNet50 i Swin Transformer, które przy 1000 próbkach osiągają odpowiednio 0.703 oraz 0.711. Wysoka dynamika przyrostu skuteczności wraz ze wzrostem dostępnych przykładów świadczy o efektywności procesu fine-tuningu i adaptacji do docelowego rozkładu danych. MedViT natomiast osiąga dokładność na poziomie 0.689 przy wykorzystaniu 1000 próbek uczących, co plasuje go na porównywalnym poziomie względem pozostałych architektur.

Analiza wyników wskazuje na wyraźną poprawę skuteczności wszystkich modeli wraz ze wzrostem liczby próbek uczących. Swin Transformer oraz ResNet50 systematycznie osiągają najwyższe rezultaty, wykazując dobrą zdolność uogólniania nawet przy ograniczonym nadzorze. MedViT prezentuje stabilne i konkurencyjne wyniki, natomiast RETFound, choć mniej skuteczny, wykazuje wzrost dokładności wraz ze zwiększaniem rozmiaru zbioru treningowego. Ogólnie rzecz biorąc, wszystkie modele wykazują pozytywną skalowalność względem ilości danych.


Na Rysunkach 4.9 - 4.12 przedstawiono wykresy krzywej uczenia dla poszczególnych modeli.




Rys. 4.9: Krzywa uczenia dla modelu RETFound



Rys. 4.10: Krzywa uczenia dla modelu Swin Transformer




Rys. 4.11: Krzywa uczenia dla modelu MedViT



Rys. 4.12: Krzywa uczenia dla modelu ResNet50


4.4. Wyjaśnialność

Na Rysunku 4.13 przedstawiono porównanie obrazu prawidłowej siatkówki z obrazem wykazującym cechy retinopatii cukrzycowej. Zestawienie to umożliwia identyfikację charakterystycznych zmian patologicznych w dnie oka, które stanowiły punkt odniesienia w ocenie jakości wizualizacji oraz trafności lokalizacji obszarów aktywacji generowanych przez zastosowane metody wyjaśnialności decyzji modeli.




Rys. 4.13: Zdrowa siatkówka i siatkówka z anomaliami charakterystycznymi dla retinopatii cukrzycowej


Na rysunkach 4.14 – 4.16 zaprezentowano wyniki wizualizacji metodą Grad-CAM dla wybranych modeli, z wyłączeniem RETFound. Z uwagi na złożoność architektury tego ostatniego oraz ograniczone doświadczenie autora, nie udało się wygenerować odpowiednich map cieplnych dla modelu RETFound. Po lewej stronie znajduje się oryginalne zdjęcie siatkówki, ocenione przez klinicystę jako klasa 4 (proliferacyjna retinopatia cukrzycowa).



Rys. 4.14: Wykres Grad-CAM dla ResNet50



Rys. 4.15: Wykres Grad-CAM dla MedVit



Rys. 4.16: Wykres Grad-CAM dla Swin Transformer

Z powyższych map cieplnych można zauważyć, że ResNet wykazuje charakterystyczną dla siebie ogólność - nie wskazuje precyzyjnych obszarów decyzyjnych, lecz akcentuje szeroki fragment siatkówki, z dominującym wpływem rozproszonego obszaru w centralnej części obrazu. Taka wizualizacja sugeruje, że model podejmuje decyzje na podstawie bardziej globalnych cech obrazu, co może ograniczać interpretowalność i precyzję lokalizacji istotnych zmian patologicznych.

MedViT oraz Swin Transformer wykazały się zdecydowanie większą precyzją w lokalizacji obszarów wpływających na decyzję modelu. MedViT wyróżnił się największą szczegółowością, zaznaczając bardzo konkretne fragmenty obrazu, które miały kluczowe znaczenie dla klasyfikacji. Swin Transformer również wyodrębnił wyraźne obszary zainteresowania, jednak ich liczba i szczegółowość były mniejsze w porównaniu do MedViT. Taka różnica może świadczyć o różnych mechanizmach uwagi i sposobach interpretacji cech przez te architektury.

W związku z powyższymi obserwacjami, uznano, że w analizowanym przypadku, przy wykorzystaniu konkretnego zbioru danych, wybranych modeli oraz metody Grad-CAM, to architektura MedViT najskuteczniej przedstawia uzasadnienie podejmowanej decyzji. Model ten w największym stopniu był w stanie uwidocznić obszary obrazu, które miały istotny wpływ na wynik klasyfikacji, co świadczy o jego wysokim potencjale w kontekście wyjaśnialności.

Dodatkowo autor, wykorzystując zdobytą wiedzę w zakresie diagnostyki obrazowej dla przypadku retinopatii cukrzycowej, wskazuje na zgodność lokalizacji obszarów uwidocznionych na mapach Grad-CAM z rzeczywistymi cechami patologicznymi obrazu dna oka, które mogą świadczyć o obecności schorzenia. W szczególności, obecność białych plamek, znaczny rozrost naczyń krwionośnych, wylewy krwi oraz tzw. twarde wysięki są charakterystyczne dla zaawansowanych stadiów choroby. Zatem obserwowane na mapach cieplnych aktywacje w tych rejonach można uznać za uzasadnione i diagnostycznie trafne.

W związku z powyższym, w niniejszej pracy uznano, że stosowanie metod wizualizacji decyzji w zadaniach opartych na analizie obrazów jest zasadne, ponieważ umożliwia identyfikację obszarów mających kluczowy wpływ na wynik predykcji. Techniki te mogą pełnić funkcję pomocniczego narzędzia diagnostycznego – zarówno dla lekarzy, jak i dla osób bez specjalistycznej wiedzy medycznej. Zrozumienie mechanizmów działania modeli pozwala nie tylko interpretować ich decyzje, lecz także usprawniać sam proces uczenia. W kontekście retinopatii cukrzycowej, która charakteryzuje się dużym zróżnicowaniem i złożonością zmian patologicznych widocznych na dnie oka, precyzyjna lokalizacja anomalii jest szczególnie istotna, ale również trudna i podatna na błędy. Zastosowane modele dobrze poradziły sobie z identyfikacją kluczowych obszarów, jednak ostateczna ocena klinicysty pozostaje niezbędna. Dodatkowo, odpowiedni dobór zarówno architektury modelu, jak i metody wizualizacji, ma istotny wpływ na jakość oraz przydatność uzyskanych wyników.

Rozdział 5

Wyzwania i ograniczenia

W poniższym rozdziale przedstawiono kluczowe trudności, z jakimi mierzone się podczas badań, co miało istotny wpływ na czas realizacji pracy.

5.1. Implementacja modeli oraz przetwarzanie obrazów

Analizowane modele cechowały się zróżnicowaną architekturą, co przejawiało się w różnym stopniu złożoności ich implementacji oraz wymagań obliczeniowych. Modele takie jak ResNet50 wyróżniały się względną prostotą architektury, co ułatwiało ich implementację oraz optymalizację w ramach eksperymentu. W przeciwieństwie do tego, bardziej zaawansowane i rozbudowane modele, na przykład RETFound czy MedViT, wiązały się z większymi wyzwaniami implementacyjnymi. Pierwotna implementacja modeli charakteryzowała się znaczącymi trudnościami, które negatywnie wpływały na jakość uzyskiwanych wyników. Zbalansowana dokładność klasyfikacji z początku osiągała poziom gorszy niż losowy klasyfikator, co wskazywało na brak skuteczności modeli w rozróżnianiu klas. Analiza przyczyn złych wyników wykazała, że problem ten był skutkiem zarówno błędów w implementacji samych architektur, jak i nieodpowiedniego przygotowania oraz zbalansowania danych treningowych. Niedokładna konfiguracja modelu, w połączeniu z nierównomiernym rozkładem klas w zbiorze danych, ograniczała zdolność modelu do generalizacji na nowych próbkach. Dodatkowym wyzwaniem okazało się wstępne przetwarzanie danych. Na początkowym etapie eksperymentu zastosowano techniki normalizacji i augmentacji, które nie były dostosowane do specyfiki architektur wykorzystanych modeli. Obrazy siatkówki poddano skalowaniu, modyfikacjom kontrastu czy usuwaniem tła obrazu siatkówki w sposób, który mógł prowadzić do utraty istotnych informacji w oryginalnych próbkach. Takie niedopasowanie procedur wstępnego przetwarzania do wymagań konkretnych architektur sieci neuronowych skutkowało spadkiem jakości danych wejściowych, a tym samym ograniczało efektywność procesu uczenia. Po wprowadzeniu zmian dotyczących wstępnego przetwarzania danych oraz po zmodyfikowaniu implementacji architektur, modele zaczęły uzyskiwać porządane wyniki.

5.2. Interpretacja metryk badających zdolność do transferu wiedzy

Kluczowym problemem okazała się niestabilność uzyskanych wyników metryk mierzących zdolność do transferu wiedzy, która znacząco utrudniała ich rzetelną interpretację oraz ocenę jakości transferu. Niestabilność wyników mogła wynikać z charakterystyki danych oraz architektur badanych modeli. Te z nich, które posiadają bardziej skomplikowaną architekturę, wykazały słabszą zdolność do transferu wiedzy w porównaniu do bardziej uniwersalnych modeli. Przykła-

dowo RETFound, model wstępnie wytrenowany na zbiorach obrazów siatkówki, czyli danych wykorzystywanych w niniejszym badaniu, teoretycznie powinien przeważać w adaptacji do zadania diagnozy retinopatii cukrzycowej. Mimo tego, złożoność i specyfika modelu mogły powodować, że jego efektywność w kontekście metryk oceniających transfer wiedzy była niższa niż oczekiwana.

5.3. Ograniczenia sprzętowe

W kontekście ograniczonych zasobów obliczeniowych, proces treningu modeli okazał się wyjątkowo czasochłonny. Pojedyncza epoka treningowa dla wybranego modelu trwała od kilku do kilkunastu godzin, co znacząco wpływało na tempo realizacji eksperymentów. Każdorazowa potrzeba zmiany parametrów treningowych wiązała się z koniecznością powtórnego przeprowadzenia pełnego procesu trenowania. Taka sytuacja znacząco ograniczała elastyczność w eksperymentowaniu oraz wydłużała czas potrzebny na optymalizację i dostosowanie modeli do wymagań zadania.

Rozdział 6

Podsumowanie

6.1. Efekt końcowy pracy

Przedstawiona praca przeprowadziła szczegółową analizę wybranych architektur głębokiego uczenia w kontekście zadania klasyfikacji stopnia zaawansowania retinopatii cukrzycowej. Ocenie poddano zarówno efektywność tych modeli w detekcji schorzenia, jak i ich zdolność do transferu wyuczonych reprezentacji między zadaniami.

W kontekście analizy wpływu wcześniejszego wytrenowania modeli na ich zdolność adaptacji do nowego zadania, nie jest możliwe jednoznaczne porównanie badanych architektur. Wynika to zarówno z odmienności ich struktur, jak i faktu, że modele zostały pierwotnie wytrenowane na różnych zbiorach danych - częściowo zbieżnych, jednak wciąż stanowiących odrębne zestawy. Ponadto wykazano, że stosowane metryki służące ocenie transferu wiedzy cechują się niestabilnością w przypadku zadań klasyfikacji obrazów, co zostało szczegółowo omówione w rozdziale 4. Z tego względu uznano, iż na podstawie uzyskanych wyników nie jest możliwe jednoznaczne wskazanie architektury najlepiej dostosowanej do diagnostyki retinopatii cukrzycowej jedynie w oparciu o ocenę efektywności transferu wiedzy.

Z uwagi na zróżnicowane aspekty skuteczności badanych modeli w zadaniu klasyfikacji obrazów dna oka, wnioskuje się, że wybór „najlepszego” modelu jest uzależniony od przyjętych priorytetów ewaluacyjnych. W kontekście zbalansowanej dokładności najwyższy wynik osiągnął model RETFound. Jednakże jego najniższa wartość współczynnika QWK (Quadratic Weighted Kappa) sugeruje, że popełniane przez niego błędy mają istotną wagę, np. błędna klasyfikacja pomiędzy skrajnie różnymi klasami (takimi jak klasa 1 i 4). Z kolei modele MedViT i ResNet50 charakteryzują się najwyższymi wartościami współczynnika QWK, co świadczy o mniejszej skali popełnianych błędów oraz większej spójności predykcji. Jednocześnie ich zbalansowana dokładność pozostaje na zadowalającym poziomie, co czyni je bardziej stabilnymi w kontekście zastosowań wymagających większej precyzji diagnostycznej. Pod względem wartości metryki ROC AUC, MedViT przewyższa ResNet50, co może być efektem wcześniejszego trenowania na danych medycznych, przekładającego się na lepszą zdolność odróżniania klas. Z kolei Swin Transformer, mimo uzyskania najwyższej wartości ROC AUC, osiągnął jeden z najniższych wyników QWK (tuż po RETFound), co wskazuje na wyraźne rozbieżności w jakości klasyfikacji pomiędzy poszczególnymi klasami.

W związku z powyższymi obserwacjami, w niniejszej pracy przyjęto, iż dobór odpowiednich metryk ewaluacyjnych stanowi element kluczowy w ocenie skuteczności modeli głębokiego uczenia. W zależności od przyjętego celu czy to maksymalizacja ogólnej dokładności predykcji,

czy minimalizacja istotności popełnianych błędów, konieczne jest dostosowanie kryteriów oceny do specyfiki problemu. Wyniki eksperymentów wskazują jednak, że żaden z analizowanych modeli nie osiągnął na tyle wysokiego poziomu skuteczności, aby móc samodzielnie, bez udziału specjalisty, precyzyjnie określić stopień zaawansowania retinopatii cukrzycowej. W kontekście zastosowania klinicznego, bardziej pożądanym podejściem wydaje się być minimalizacja błędów o dużej wadze diagnostycznej, nawet kosztem spadku ogólnej dokładności. Oznacza to, że preferowane są sytuacje, w których model popełnia tzw. błędy „niskiego ryzyka”, np. klasyfikacja przypadków z klasy 2 jako klasa 3, zamiast błędów polegających na rozpoznawaniu skrajnie różnych stanów klinicznych. Biorąc pod uwagę, że ostateczna decyzja diagnostyczna należy do lekarza, rolą modelu może być wsparcie procesu diagnostycznego poprzez wstępną selekcję lub wskazanie przypadków wymagających szczególnej uwagi, nawet jeżeli predykcja nie jest całkowicie trafna.

W kontekście metod wyjaśnialnej sztucznej inteligencji wykazano, iż ich implementacja jest szczególnie istotna w sytuacjach wymagających analizy decyzji podejmowanych przez modele uczenia maszynowego. Zastosowanie technik XAI umożliwia identyfikację obszarów obrazu, które w największym stopniu wpłynęły na wynik predykcji, co pozwala na częściową interpretację wewnętrznych mechanizmów działania modelu, nawet przy ograniczonej wiedzy dziedzinowej ze strony użytkownika. W szczególności, wykorzystanie mechanizmów wizualizacji umożliwia wskazanie regionów siatkówki uznanych przez model za istotne diagnostycznie. Takie podejście nie tylko zwiększa transparentność działania algorytmu, ale również pozwala na identyfikację potencjalnych błędów lub nieintuicyjnych wzorców decyzyjnych. Ma to kluczowe znaczenie w zastosowaniach medycznych, gdzie wiarygodność i interpretowalność modelu są krytyczne z punktu widzenia klinicznego. Ponadto, zrozumienie wewnętrznych zależności i logiki działania modelu umożliwia jego dalszą optymalizację, co jest kluczowe w kontekście rozwoju technologii sztucznej inteligencji i zwiększania jej użyteczności.

6.2. **Możliwe ścieżki rozwoju**

Niniejsza praca stanowi punkt wyjścia do dalszych badań, które mogą objąć rozszerzenie analizy o dodatkowe architektury modeli głębokiego uczenia, w celu oceny ich skuteczności w klasyfikacji stopnia zaawansowania retinopatii cukrzycowej. Włączenie większej liczby modeli pozwoliłoby na dokładniejsze porównanie ich potencjału w kontekście analizy obrazów siatkówki.

W przyszłości możliwe jest również przeprowadzenie eksperymentów na zróżnicowanych zbiorach danych, obejmujących nie tylko fotografie dna oka, ale także inne rodzaje obrazów medycznych, takie jak tomografie komputerowe, zdjęcia rentgenowskie czy obrazy z rezonansu magnetycznego. Pozwoliłoby to na ocenę stopnia uniwersalności poszczególnych modeli oraz ich zdolności adaptacyjnych do różnych dziedzin medycyny.

W kontekście uczenia transferowego, praca może zostać rozwinięta poprzez zastosowanie szerszego zestawu metryk służących do oceny efektywności transferu wiedzy, jak również poprzez porównanie wyników tego samego modelu na wielu, różnorodnych zbiorach danych. Dzięki temu możliwe byłoby określenie, na których zbiorach dany model osiąga lepsze rezultaty, a gdzie jego skuteczność spada, co dostarczyłoby wartościowych informacji na temat specyfiki danego rozwiązania.

Z perspektywy wyjaśnialności decyzji modeli, przyszłe prace mogłyby uwzględniać inne, być może bardziej precyzyjne techniki interpretacyjne. Zastosowanie alternatywnych metod mogłoby przyczynić się do głębszego zrozumienia mechanizmów stojących za predykcjami modeli i zwięks-

szyc ich transparentność, co ma szczególne znaczenie w kontekście zastosowań medycznych. Jednym z potencjalnych kierunków dalszych badań jest rozszerzenie analizy interpretowalności modeli o komponent ekspercki oparty na rzeczywistej wiedzy medycznej. Dotychczasowa interpretacja heatmap opierała się głównie na ocenie ich spójności z intuicją użytkownika bez specjalistycznego przygotowania diagnostycznego. Włączenie do procesu oceny lekarzy okulistów lub ekspertów w dziedzinie retinopatii cukrzycowej pozwoliłoby na weryfikację, czy wskazywane przez model obszary faktycznie odpowiadają zmianom patologicznym istotnym z punktu widzenia praktyki klinicznej.

Literatura

- [1] Joanne WY Yau, Sophie L Rogers, Ryo Kawasaki, Ecosse L Lamoureux, Jonathan W Kowalski, Toke Bek, Shih-Jen Chen, Jacqueline M Dekker, Astrid Fletcher, Jakob Grauslund, et al. Global prevalence and major risk factors of diabetic retinopathy. *Diabetes care*, 35(3):556–564, 2012.
- [2] Institute for Health Metrics and Evaluation. Global estimates of the number of people blind or visually impaired by diabetic retinopathy. <https://www.healthdata.org/research-analysis/library/global-estimates-number-people-blind-or-visually-impaired-diabetic>, 2020. Dostęp: 15 maja 2025.
- [3] Tien-En Tan and Tien Yin Wong. Diabetic retinopathy: Looking forward to 2030. *Frontiers in Endocrinology*, 13:1077669, 2023.
- [4] Michael D Abràmoff, Philip T Lavin, Michele Birch, Nilay Shah, and James C Folk. Pivotal trial of an autonomous ai-based diagnostic system for detection of diabetic retinopathy in primary care offices. *NPJ digital medicine*, 1(1):39, 2018.
- [5] Malavika Bhaskaranand, Chaithanya Ramachandra, Sandeep Bhat, Jorge Cuadros, Muneswar G Nittala, Srinivas R Sadda, and Kaushal Solanki. The value of automated diabetic retinopathy screening with the eyeart system: a study of more than 100,000 consecutive encounters from people with diabetes. *Diabetes technology & therapeutics*, 21(11):635–643, 2019.
- [6] Yuchen Xie, Quang D Nguyen, Haslina Hamzah, Gilbert Lim, Valentina Bellemo, Dinesh V Gunasekeran, Michelle YT Yip, Xin Qi Lee, Wynne Hsu, Mong Li Lee, et al. Artificial intelligence for teleophthalmology-based diabetic retinopathy screening in a national programme: an economic analysis modelling study. *The Lancet Digital Health*, 2(5):e240–e249, 2020.
- [7] Wei Ying, Yu Zhang, Junzhou Huang, and Qiang Yang. Transfer learning via learning to transfer. In *International conference on machine learning*, pages 5085–5094. PMLR, 2018.
- [8] Asmaul Hosna, Ethel Merry, Jigmei Gyalmo, Zulfikar Alom, Zeyar Aung, and Mohammad Abdul Azim. Transfer learning: a friendly introduction. *Journal of Big Data*, 9(1):102, 2022.
- [9] Michal Wozniak. *Hybrid classifiers: methods of data, knowledge, and classifier combination*, volume 519. Springer, 2013.
- [10] Rene Y Choi, Aaron S Coyner, Jayashree Kalpathy-Cramer, Michael F Chiang, and J Peter Campbell. Introduction to machine learning, neural networks, and deep learning. *Translational vision science & technology*, 9(2):14–14, 2020.

-
- [11] Leiyu Chen, Shaobo Li, Qiang Bai, Jing Yang, Sanlong Jiang, and Yanming Miao. Review of image classification algorithms based on convolutional neural networks. *Remote Sensing*, 13(22):4712, 2021.
 - [12] Shutao Li, Weiwei Song, Leyuan Fang, Yushi Chen, Pedram Ghamisi, and Jon Atli Benediktsson. Deep learning for hyperspectral image classification: An overview. *IEEE transactions on geoscience and remote sensing*, 57(9):6690–6709, 2019.
 - [13] Geert Litjens, Thijs Kooi, Babak Ehteshami Bejnordi, Arnaud Arindra Adiyoso Setio, Francesco Ciompi, Mohsen Ghafoorian, Jeroen Awm Van Der Laak, Bram Van Ginneken, and Clara I Sánchez. A survey on deep learning in medical image analysis. *Medical image analysis*, 42:60–88, 2017.
 - [14] Maggie S Chen, Rohith Ravindranath, Robert Chang, Yukun Zhou, Pearse A Keane, and Sophia Y Wang. Independent evaluation of retfound foundation model’s performance on optic nerve analysis using fundus photography. *Ophthalmology Science*, page 100720, 2025.
 - [15] David Ruppert. The elements of statistical learning: data mining, inference, and prediction, 2004.
 - [16] Michael P LaValley. Logistic regression. *Circulation*, 117(18):2395–2399, 2008.
 - [17] Jiaji Wang, Shuihua Wang, and Yudong Zhang. Deep learning on medical image analysis. *CAAI Transactions on Intelligence Technology*, 10(1):1–35, 2025.
 - [18] Le Feng, Yuan Yang, Mian Tan, Taotao Zeng, Huachun Tang, Zhiling Li, Zhizhong Niu, and Fujian Feng. Adaptive multi-source domain collaborative fine-tuning for transfer learning. *PeerJ Computer Science*, 10:e2107, 2024.
 - [19] Wen Zhang, Lingfei Deng, Lei Zhang, and Dongrui Wu. A survey on negative transfer. *IEEE/CAA Journal of Automatica Sinica*, 10(2):305–329, 2022.
 - [20] Kaiming He, Xinlei Chen, Saining Xie, Yanghao Li, Piotr Dollár, and Ross Girshick. Masked autoencoders are scalable vision learners. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, pages 16000–16009, 2022.
 - [21] Juzhao Zhang, Senlin Lin, Tianhao Cheng, Yi Xu, Lina Lu, Jiangnan He, Tao Yu, Yajun Peng, Yuejie Zhang, Haidong Zou, et al. Retfound-enhanced community-based fundus disease screening: real-world evidence and decision curve analysis. *NPJ digital medicine*, 7(1):108, 2024.
 - [22] Yukun Zhou, Mark A Chia, Siegfried K Wagner, Murat S Ayhan, Dominic J Williamson, Robbert R Struyven, Timing Liu, Moucheng Xu, Mateo G Lozano, Peter Woodward-Court, et al. A foundation model for generalizable disease detection from retinal images. *Nature*, 622(7981):156–163, 2023.
 - [23] Kai Han, Yunhe Wang, Hanting Chen, Xinghao Chen, Jianyuan Guo, Zhenhua Liu, Yehui Tang, An Xiao, Chunjing Xu, Yixing Xu, et al. A survey on vision transformer. *IEEE transactions on pattern analysis and machine intelligence*, 45(1):87–110, 2022.
 - [24] Omid Nejati Manzari, Hamid Ahmadabadi, Hossein Kashiani, Shahriar B Shokouhi, and Ahmad Ayatollahi. Medvit: a robust vision transformer for generalized medical image classification. *Computers in biology and medicine*, 157:106791, 2023.
 - [25] Jingyun Liang, Jiezhong Cao, Guolei Sun, Kai Zhang, Luc Van Gool, and Radu Timofte. Swinir: Image restoration using swin transformer. In *Proceedings of the IEEE/CVF international conference on computer vision*, pages 1833–1844, 2021.
-

-
- [26] Ze Liu, Yutong Lin, Yue Cao, Han Hu, Yixuan Wei, Zheng Zhang, Stephen Lin, and Baining Guo. Swin transformer: Hierarchical vision transformer using shifted windows. In *Proceedings of the IEEE/CVF international conference on computer vision*, pages 10012–10022, 2021.
 - [27] Ahmet Çınar, Muhammed Yıldırım, and Yeşim Eroğlu. Classification of pneumonia cell images using improved resnet50 model. *Traitement du Signal*, 38(1):165–173, 2021.
 - [28] Wejdan L Alyoubi, Wafaa M Shalash, and Maysoon F Abulkhair. Diabetic retinopathy detection through deep learning techniques: A review. *Informatics in Medicine Unlocked*, 20:100377, 2020.
 - [29] Kele Xu, Dawei Feng, and Haibo Mi. Deep convolutional neural network-based early automated detection of diabetic retinopathy using fundus image. *Molecules*, 22(12):2054, 2017.
 - [30] Varun Gulshan, Lily Peng, Marc Coram, Martin C Stumpe, Derek Wu, Arunachalam Narayanaswamy, Subhashini Venugopalan, Kasumi Widner, Tom Madams, Jorge Cuadros, et al. Development and validation of a deep learning algorithm for detection of diabetic retinopathy in retinal fundus photographs. *jama*, 316(22):2402–2410, 2016.
 - [31] Xiaoliang Wang, Yongjin Lu, Yujuan Wang, and Wei-Bang Chen. Diabetic retinopathy stage classification using convolutional neural networks. In *2018 IEEE international conference on information reuse and integration (IRI)*, pages 465–471. IEEE, 2018.
 - [32] Sharzil Haris Khan, Zeeshan Abbas, SM Danish Rizvi, et al. Classification of diabetic retinopathy images based on customised cnn architecture. In *2019 Amity International conference on artificial intelligence (AICAI)*, pages 244–248. IEEE, 2019.
 - [33] Ilias Tougui, Abdelilah Jilbab, and Jamal El Mhamdi. Impact of the choice of cross-validation techniques on the results of machine learning-based diagnostic applications. *Healthcare informatics research*, 27(3):189–199, 2021.
 - [34] Juan Terven, Diana M Cordova-Esparza, Alfonso Ramirez-Pedraza, Edgar A Chavez-Urbiola, and Julio A Romero-Gonzalez. Loss functions and metrics in deep learning. *arXiv preprint arXiv:2307.02694*, 2023.
 - [35] Afrizal Doewes, Nugthoh Kurdhi, and Akrati Saxena. Evaluating quadratic weighted kappa as the standard performance metric for automated essay scoring. In *16th International Conference on Educational Data Mining, EDM 2023*, pages 103–113. International Educational Data Mining Society (IEDMS), 2023.
 - [36] Long-Kai Huang, Junzhou Huang, Yu Rong, Qiang Yang, and Ying Wei. Frustratingly easy transferability estimation. In Kamalika Chaudhuri, Stefanie Jegelka, Le Song, Csaba Szepesvari, Gang Niu, and Sivan Sabato, editors, *Proceedings of the 39th International Conference on Machine Learning*, volume 162 of *Proceedings of Machine Learning Research*, pages 9201–9225. PMLR, 17–23 Jul 2022.
 - [37] Kaichao You, Yong Liu, Jianmin Wang, and Mingsheng Long. Logme: Practical assessment of pre-trained models for transfer learning. In *International Conference on Machine Learning*, pages 12133–12143. PMLR, 2021.
 - [38] Cuong Nguyen, Tal Hassner, Matthias Seeger, and Cedric Archambeau. Leep: A new measure to evaluate transferability of learned representations. In *International Conference on Machine Learning*, pages 7294–7305. PMLR, 2020.
-

-
- [39] Yang Tan, Yang Li, and Shao-Lun Huang. Otce: A transferability metric for cross-domain cross-task representations. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, pages 15779–15788, 2021.
- [40] Sasan Karamizadeh, Shahidan M Abdullah, Azizah A Manaf, Mazdak Zamani, and Alireza Hooman. An overview of principal component analysis. *Journal of signal and information processing*, 4(3):173–175, 2013.
- [41] Martin Wattenberg, Fernanda Viégas, and Ian Johnson. How to use t-sne effectively. *Distill*, 1(10):e2, 2016.
- [42] Prasad Pasam Thulasiram. Explainable artificial intelligence (xai): Enhancing transparency and trust in machine learning models. 2025.
- [43] Rami Al-Dahdooh, Ahmad Marouf, Mahmoud Jamal Abu Ghali, Ali Osama Mahdi, Bassem S. Abu-Nasser, and Samy S. Abu-Naser. Explainable ai (xai). *International Journal of Academic Information Systems Research (IJASIR)*, 9(1):65–70, 2025.
- [44] Edoardo Mosca, Ferenc Szigeti, Stella Tragianni, Daniel Gallagher, and Georg Groh. Shap-based explanation methods: a review for nlp interpretability. In *Proceedings of the 29th international conference on computational linguistics*, pages 4593–4603, 2022.
- [45] Md Nahiduzzaman, Lway Faisal Abdulrazak, Mohamed Arselene Ayari, Amith Khandakar, and SM Riazul Islam. A novel framework for lung cancer classification using lightweight convolutional neural networks and ridge extreme learning machine model with shapley additive explanations (shap). *Expert Systems with Applications*, 248:123392, 2024.
- [46] Corne Van Zyl, Xianming Ye, and Raj Naidoo. Harnessing explainable artificial intelligence for feature selection in time series energy forecasting: A comparative analysis of grad-cam and shap. *Applied Energy*, 353:122079, 2024.
- [47] Mohammad Ennab and Hamid Mcheick. Advancing ai interpretability in medical imaging: A comparative analysis of pixel-level interpretability and grad-cam models. *Machine Learning and Knowledge Extraction*, 7(1):12, 2025.
- [48] Kaggle. Diabetic retinopathy detection. <https://www.kaggle.com/competitions/diabetic-retinopathy-detection/data>, 2015. Dostęp: 15 maja 2025.
- [49] Andrea Agostinelli, Michal Pándy, Jasper Uijlings, Thomas Mensink, and Vittorio Ferrari. How stable are transferability metrics evaluations? In *European Conference on Computer Vision*, pages 303–321. Springer, 2022.
- [50] Levy Chaves, Alceu Bissoto, Eduardo Valle, and Sandra Avila. The performance of transferability metrics does not translate to medical tasks. In *MICCAI Workshop on Domain Adaptation and Representation Transfer*, pages 105–114. Springer, 2023.